



CENTRO FEDERAL DE EDUCAÇÃO TECNOLÓGICA CELSO SUCKOW DA FONSECA
CURSO DE SISTEMAS DE INFORMAÇÃO

UMA ANÁLISE DE TÉCNICAS DE IA PARA DETECÇÃO DE SINAIS DA DEPRESSÃO

**ANA BEATRIZ DE MELLO PEREIRA
GABRIEL DE SOUZA GUERÇO RODRIGUES**

Orientador: Rafael Elias de Lima Escalfoni
CEFET/RJ Campus Nova Friburgo

Coorientador: Silas Pereira Lima Filho
UFRJ

NOVA FRIBURGO
AGOSTO DE 2026

**ANA BEATRIZ DE MELLO PEREIRA
GABRIEL DE SOUZA GUERÇO RODRIGUES**

**UMA ANÁLISE DE TÉCNICAS DE IA
PARA DETECÇÃO DE SINAIS DA
DEPRESSÃO**

Trabalho de Conclusão de Curso (Graduação)
apresentado ao Curso de Sistemas de Informação
do Centro Federal de Educação Tecnológica Celso
Suckow da Fonseca, como requisito parcial para
a obtenção do título de Bacharel em Sistemas de
Informação.

Orientador: Rafael Elias de Lima Escalfoni
CEFET/RJ Campus Nova Friburgo

Coorientador: Silas Pereira Lima Filho
UFRJ

CENTRO FEDERAL DE EDUCAÇÃO TECNOLÓGICA CELSO SUCKOW DA FONSECA
CURSO DE SISTEMAS DE INFORMAÇÃO
NOVA FRIBURGO
AGOSTO DE 2026

P436a Pereira, Ana Beatriz de Mello.
Uma análise de técnicas de IA para detecção de sinais da depressão. / Ana Beatriz de Mello Pereira, Gabriel de Souza Guerço Rodrigues. – Nova Friburgo, RJ: 2026.
xi, 84f.: il. (color.) : em PDF.

Trabalho de Conclusão de Curso (Sistemas de Informação) -
Centro Federal de Educação Tecnológica Celso Suckow da
Fonseca, 2026.

Bibliografia: f. 77-84.

Orientador: Rafael Elias de Lima Escalfoni.

Coorientador: Silas Pereira Lima Filho.

1. Sistemas de Informação. 2. Inteligência Artificial (IA). 3.
Depressão mental. 4. Redes sociais on-line I. Rodrigues, Gabriel
de Souza Guerço (Coautor). II. Escalfoni, Rafael Elias de Lima
(orientador). III. Lima Filho, Silas Pereira (Coorientador). IV.
Título.

CDD 658.4038

CENTRO FEDERAL DE EDUCAÇÃO TECNOLÓGICA
CELSO SUCKOW DA FONSECA – CEFET/RJ

Uma Análise de Técnicas de IA para Detecção de Sinais da Depressão

Ana Beatriz de Mello Pereira
Gabriel de Souza Guerço Rodrigues

Projeto final apresentado ao curso de Bacharelado em Sistemas de Informação do CEFET/RJ Nova Friburgo em cumprimento às normas do Departamento de Educação Superior do CEFET/RJ, como parte dos requisitos para obtenção do título de Bacharel em Sistemas de Informação.

Banca Examinadora:

Documento assinado digitalmente
 **RAFAEL ELIAS DE LIMA ESCALFONI**
Data: 04/08/2026 12:34:03-0300
Verifique em <https://validar.iti.gov.br>

Professor Rafael Elias de Lima Escalfoni (CEFET-RJ) (Orientador)

Documento assinado digitalmente
 **SILAS PEREIRA LIMA FILHO**
Data: 04/08/2026 13:35:59-0300
Verifique em <https://validar.iti.gov.br>

Professor Silas Pereira Lima Filho (UFRJ) (Coorientador)

Documento assinado digitalmente
 **ELIEZER DUTRA GONCALVES**
Data: 04/08/2026 17:30:40-0300
Verifique em <https://validar.iti.gov.br>

Professor Eliezer Dutra Gonçalves (CEFET-RJ)

Documento assinado digitalmente
 **VITOR PADILHA GONCALVES**
Data: 04/08/2026 20:37:10-0300
Verifique em <https://validar.iti.gov.br>

Professor Vitor Padilha Gonçalves (CEFET-RJ)

Documento assinado digitalmente
 **TIAGO CRUZ DE FRANCA**
Data: 04/08/2026 16:53:59-0300
Verifique em <https://validar.iti.gov.br>

Professor Tiago Cruz de França (UFRRJ)

Nova Friburgo
Agosto de 2026

Eu, Gabriel Guerço, dedico este trabalho a minha mãe, Aldi, que durante toda a minha caminhada sempre prestou todo suporte e incentivo, possibilitando que concluísse cada etapa e que me tornasse a pessoa que hoje sou.

Eu, Ana Beatriz, dedico este trabalho a todos os que me ajudaram ao longo desta jornada. Especialmente aos meus pais Tatiana e Fabrício, ao meu irmão João Victor e aos meus avôs Adelaide e José Paulo por serem figuras que sempre me apoiaram na minha caminhada pessoal e amadurecimento.

Agradecimentos

Agradecemos, primeiramente, aos nossos familiares, que nos ofereceram todo o suporte necessário para que pudéssemos superar cada etapa até chegarmos aqui. Agradecemos, também, aos nossos professores orientadores, Rafael Elias de Lima Escalfoni e Silas Pereira Lima Filho, pela disponibilidade, orientação e apoio ao longo de todo o desenvolvimento deste trabalho, contribuindo de forma essencial para sua concepção e execução. Por fim, expressamos nossa gratidão a todos que, de alguma forma, fizeram parte dessa jornada durante a realização do curso.

“We were neither highfliers nor greedy vultures; we were merely children who loved technology.”

(Não éramos ambiciosos em busca de ascensão, nem abutres gananciosos; éramos meramente crianças que amavam a tecnologia.)

— (Yi Sang, *Limbus Company*)

“Tu, porém, terás estrelas como ninguém... Quero dizer: quando olhares o céu de noite, porque habitarei uma delas e estarei rindo, então será como se todas as estrelas te rissem! E tu terás estrelas que sabem sorrir! Assim, tu te sentirás contente por me teres conhecido. Tu serás sempre meu amigo (basta olhar para o céu e estarei lá). Terás vontade de rir comigo.”

— (Antoine de Saint-Exupéry, *O Pequeno Príncipe*)

Resumo

A saúde mental consolidou-se como um tema de crescente relevância na sociedade contemporânea, especialmente diante do impacto de transtornos como a depressão no bem-estar dos indivíduos. Nesse contexto, o uso de técnicas de Inteligência Artificial para identificar sinais depressivos em mensagens publicadas em redes sociais online tem se intensificado, ampliando as possibilidades de pesquisa e intervenção. Este trabalho está estruturado em duas etapas complementares, com o objetivo de aprofundar a compreensão desse tema. A primeira consiste na condução de um estudo exploratório sobre o panorama atual das técnicas de Inteligência Artificial aplicadas à detecção de textos depressivos em redes sociais online. A segunda corresponde à realização de um experimento prático, no qual um modelo de Inteligência Artificial é treinado com dados provenientes de diferentes redes sociais online e avaliado em distintos contextos. O estudo exploratório, conduzido sobre 114 artigos selecionados entre 2022 e 2025, revelou que modelos baseados em Transformers, com destaque para o BERT e seus derivados, predominam na área, sendo os dados textuais provenientes do Twitter e do Reddit as fontes mais recorrentes. Já no experimento aplicou-se ajuste fino no modelo RoBERTa em bases de dados focadas em classificação da depressão, investigando o impacto da mudança de domínio de rede social online no desempenho dos modelos. Os resultados confirmaram que a origem dos dados afeta substancialmente a eficácia da classificação, e que modelos treinados com dados de múltiplas redes sociais online apresentaram desempenho superior e mais equilibrado em todos os cenários avaliados, mostrando que a agregação de diferentes contextos pode ser benéfica no desenvolvimento de modelos mais robustos. Assim, o trabalho contribui para a consolidação do conhecimento sobre o estado da arte na detecção automatizada de depressão em redes sociais, ao mesmo tempo em que evidencia a relevância da diversidade de domínios no treinamento de modelos mais robustos e generalizáveis.

Palavras-chave: Depressão, redes sociais online, inteligência artificial, processamento de linguagem natural.

Abstract

Mental health has become a topic of growing relevance in contemporary society, especially due to the impact of disorders such as depression on individuals' well-being. In this context, the use of Artificial Intelligence techniques to identify depressive signals in messages published on online social networks has intensified, expanding the possibilities for research and intervention. This work is structured into two complementary stages, aiming to deepen the understanding of this topic. The first stage consists of conducting an exploratory study on the current landscape of Artificial Intelligence techniques applied to the detection of depressive texts in online social networks. The second stage corresponds to a practical experiment in which an Artificial Intelligence model is trained using data from different online social networks and evaluated across different contexts. The exploratory study, conducted on 114 articles selected between 2022 and 2025, revealed that Transformer-based models, particularly BERT and its variants, predominate in the field, with textual data from Twitter and Reddit being the most frequently used sources. In the experiment, the RoBERTa model was fine-tuned on datasets focused on depression classification, investigating the impact of changing the online social network domain on model performance. The results confirmed that the origin of the data substantially affects classification performance and that models trained with data from multiple online social networks achieved superior and more balanced performance across all evaluated scenarios, demonstrating that aggregating different contexts can be beneficial for the development of more robust models. Thus, this work contributes to consolidating knowledge about the state of the art in automated depression detection on online social networks while highlighting the relevance of domain diversity for training more robust and generalizable models.

Keywords: Depression, online social networks, artificial intelligence, natural language processing.

Lista de Figuras

Figura 1 – Fluxo do processo metodológico para seleção dos artigos	27
Figura 2 – Distribuição de artigos por plataforma	29
Figura 3 – Proporção de artigos aceitos por base	30
Figura 4 – Variação do número de artigos ao longo das etapas do processo de seleção	32
Figura 5 – Distribuição de trabalhos por ano	33
Figura 6 – Distribuição de métodos presentes nos trabalhos	34
Figura 7 – Distribuição de plataformas presentes nos trabalhos	37
Figura 8 – Distribuição de formatos presentes nos trabalhos	38
Figura 9 – Distribuição de idiomas presentes nos trabalhos	39
Figura 10 – Distribuição das condições de saúde abordadas nos trabalhos .	40
Figura 11 – Distribuição dos tipos de classificação nos trabalhos	41
Figura 12 – Métricas Gerais (Médias)	54
Figura 13 – Aspectos Emocionais e Mentais (Médios)	56
Figura 14 – Nuvem de Palavras Reddit	57
Figura 15 – Nuvem de Palavras X	58
Figura 16 – Distribuição das classes antes do balanceamento da base do Reddit	61
Figura 17 – Distribuição de dados no dataset do Facebook	62
Figura 18 – Gráfico das Métricas dos Modelos no Dataset Reddit	66
Figura 19 – Gráfico das Métricas dos Modelos no Dataset Twitter	67
Figura 20 – Gráfico das Métricas dos Modelos no Dataset Misto	68
Figura 21 – Gráfico das Métricas dos Modelos no Dataset Facebook	69

Lista de Tabelas

Tabela 1 – Definição dos elementos da estratégia PIOC.	26
Tabela 2 – Questões de Pesquisa (QP) definidas.	26
Tabela 3 – Critérios de Inclusão e Exclusão definidos.	29
Tabela 4 – Critérios de Qualidade (CQ) definidos.	30
Tabela 5 – Variáveis e métricas utilizadas no experimento.	48
Tabela 6 – Descrição dos cenários de treinamento e teste.	48
Tabela 7 – Critérios de seleção utilizados para a coleta das bases de dados.	49
Tabela 8 – Exemplos de mensagens por nível de severidade da depressão.	50
Tabela 9 – Exemplos de mensagens presentes na base do Twitter.	51
Tabela 10 – Resumo das bases de dados utilizadas nos experimentos.	52
Tabela 11 – Médias Aproximadas de Palavras e Caracteres por Base	52
Tabela 12 – Métricas Gerais (Médias)	54
Tabela 13 – Aspectos Emocionais e Mentais (Médios)	55
Tabela 14 – Campos presentes nas bases após o pré-processamento.	63
Tabela 15 – Hiperparâmetros utilizados para o treinamento do modelo.	64
Tabela 16 – Métricas de desempenho para o Dataset Reddit: Métricas Gerais (acima) e Específicas (abaixo).	65
Tabela 17 – Métricas de desempenho para o Dataset X (Twitter): Métricas Ge- rais (acima) e Específicas (abaixo).	66
Tabela 18 – Métricas de desempenho para o Dataset Misto: Métricas Gerais (acima) e Específicas (abaixo).	68
Tabela 19 – Métricas de desempenho para o Dataset Facebook: Métricas Ge- rais (acima) e Específicas (abaixo).	69

Sumário

1 – Introdução	1
1.1 Motivação	1
1.2 Problema	2
1.3 Objetivos	3
1.4 Proposta	4
1.5 Abordagem Metodológica	5
1.6 Organização do trabalho	6
2 – Fundamentação Teórica	7
2.1 Redes Sociais	7
2.1.1 Principais Redes Online	8
2.1.2 Importância das Redes Sociais Online na Sociedade	10
2.1.3 Impactos Negativos das Redes Sociais Online	12
2.2 Transtornos de Saúde Mental	14
2.2.1 Impactos na Educação e na Saúde	14
2.3 Transtorno Depressivo	16
2.4 Inteligência Artificial (IA)	18
2.5 Processamento de Linguagem Natural	19
2.5.1 Funcionamento e Desafios Técnicos	19
2.5.2 Principais Desafios Linguísticos e Estruturais	20
2.6 Análise Lexical	21
2.7 Detecção de Sinais Depressivos via Técnicas de IA	22
2.7.1 Treinamento a partir de Dados de Redes Sociais Online	23
2.7.2 Implicações Éticas	23
2.8 Considerações Finais	24
3 – O Estudo Exploratório	25
3.1 Planejamento	25
3.2 Abordagem Metodológica	27

3.3	Resultados e Discussão	32
3.3.1	Resultados das Questões de Pesquisa	33
3.3.2	Estudos de Abordagens Distintivas	41
3.4	Considerações do Estudo	44
4	O Experimento	46
4.1	Planejamento	46
4.2	Materiais e Métodos	49
4.2.1	Bases de Dados	49
4.2.1.1	Caracterização das Bases	52
4.2.2	Modelo de Inteligência Artificial	58
4.3	Execução do Experimento	59
4.3.1	Pré-Processamento	60
4.3.2	Treinamento dos Modelos	63
4.3.3	Resultados	64
4.4	Limitações do Experimento	70
4.5	Considerações do Experimento	71
5	Conclusão	74
5.1	Trabalhos Futuros	75
	Referências	77

1 Introdução

A saúde mental é um aspecto do cotidiano que deve receber a devida atenção, especialmente após a pandemia da COVID-19, que agravou a prevalência de transtornos de mal-estar psicológico, como a depressão (OMS, 2022). Diante disso, cresce a busca por formas de combater esses transtornos. Paralelamente, o avanço das inteligências artificiais, tais como as técnicas de reconhecimento de padrões e aprendizado baseado em dados, tornou-se outro elemento de grande destaque nos últimos anos, impulsionando estudos e metodologias voltados à detecção automatizada de sinais desses transtornos por meio de técnicas de IA (JÚLIO, 2024). Diante da relevância e atualidade do tema, este capítulo apresenta a contextualização do trabalho e a definição da pesquisa, incluindo sua motivação, problema, objetivos, proposta e metodologia.

1.1 Motivação

A saúde mental assumiu um papel de destaque na sociedade contemporânea. Estimativas da Organização Mundial da Saúde indicam que uma a cada sete pessoas enfrenta algum transtorno mental, realidade que se agravou significativamente após a pandemia da COVID-19. Apenas no primeiro ano, observou-se um aumento de aproximadamente 25% nos casos de depressão e ansiedade, e os efeitos reais desse fenômeno ainda estão em processo de ser plenamente compreendidos (OMS, 2022).

No mesmo contexto, as medidas adotadas para conter a pandemia tornaram necessária a adoção de ferramentas capazes de viabilizar atividades cotidianas sem a presença física. Esse cenário fortaleceu e ampliou o uso das redes sociais online, que passaram a desempenhar um papel ainda mais central nas interações diárias, na educação e no trabalho, consolidando-se como recursos indispensáveis na sociedade contemporânea (CRUZ-RAMIREZ; OLAZA-MAGUIÑA, 2021). i Paralelamente a esse cenário, outro conceito que ganhou destaque e evoluiu de

forma acelerada foi o da Inteligência Artificial. Embora existente há décadas, esse campo sempre foi marcado por ciclos de maior e menor entusiasmo, alcançando um novo ponto de virada ao surgimento do ChatGPT em 2022. A IA (Inteligência Artificial) reúne um conjunto amplo de técnicas capazes de processar e interpretar informações complexas, entre elas a linguagem humana, e vem sendo aplicada em diversas áreas. Nesse sentido, um exemplo que tem se mostrado promissor foi a detecção de possíveis sinais associados a transtornos mentais como a depressão, conectando-se diretamente às discussões contemporâneas sobre saúde mental e ao papel crescente das interações digitais (RONGALI, 2025; BIRJALI; KASRI; BENIHSSANE, 2021).

Diante deste cenário, torna-se relevante compreender de forma aprofundada a relevância do estudo dos transtornos psicológicos e o impacto dessa questão na atualidade, bem como conhecer as técnicas de Inteligência Artificial propostas para sua detecção e o papel das redes sociais nesse cenário, possibilitando identificar e analisar as metodologias existentes, contribuindo para uma visão mais clara do tema e de sua aplicabilidade em diferentes contextos de pesquisa e intervenção.

1.2 Problema

A popularização da Inteligência Artificial e o crescente uso de redes sociais como fonte de dados para identificação de sinais de depressão motivaram o desenvolvimento de diversas técnicas e métodos de detecção automatizados. Entretanto, com o aumento de publicações sobre o tema, a organização sobre o conhecimento e a compreensão de cada um dos aspectos das técnicas, que são diversos neste campo da tecnologia, pode se tornar uma tarefa árdua. Cada estudo aborda o tópico com objetivos semelhantes, porém com características diferentes: o foco e escopo da pesquisa, os tipos de dados utilizados, as abordagens metodológicas, a língua do corpus, o algoritmo de treinamento ou o campo da IA utilizado.

Apesar de existirem na literatura esforços relevantes de revisão e sistematização dessas técnicas, a velocidade com que novas abordagens surgem e a diversidade de parâmetros utilizados tornam a organização desse conhecimento um pro-

cesso contínuo e necessário. Com a diversidade de pesquisas, um problema central surge: a dificuldade de compreender claramente como essas técnicas se comparam, convergem ou divergem, quais tendências metodológicas predominam, quais limitações são comuns e que oportunidades de aprimoramento existem. Como consequência, novos pesquisadores na área encontram dificuldades em compreender o estado da arte e identificar direções pertinentes para trabalhos futuros, como, por exemplo, identificar qual método mapeado melhor se encaixa em seu contexto de pesquisa ou aplicação prática.

Diante disso, tornou-se necessário explorar e mapear os principais métodos estudados e disponíveis, bem como analisar, ainda que de forma preliminar, possíveis relações entre características dos dados e o desempenho ou foco dessas técnicas. Esta necessidade formalizou a seguinte questão de pesquisa que norteia este trabalho: *Quais são os principais aspectos das técnicas de inteligência artificial empregadas atualmente na detecção de sinais depressivos em textos de redes sociais online e de que forma a origem dos dados utilizados no treinamento impacta o desempenho desses modelos em diferentes contextos?*

1.3 Objetivos

Conforme discutido, transtornos de saúde psicológica, como a depressão, têm recebido atenção cada vez maior. Consequentemente, cresce também o número de pesquisas que buscam compreender, reduzir ou auxiliar no manejo desses quadros. Nesse cenário, diversos modelos têm sido desenvolvidos para apoiar a identificação desses transtornos, e as redes sociais online surgem como um ambiente particularmente promissor para avaliar a eficácia dessas abordagens, uma vez que os usuários podem expor, de forma consciente ou não, indícios de seu estado emocional.

Desta forma, o estudo teve como objetivo geral realizar uma análise do panorama atual da literatura referente a técnicas de Inteligência Artificial empregadas na detecção de indícios da depressão expressados em textos de redes sociais online e aplicar um estudo sobre o impacto da mudança de contexto no desempenho de modelos de detecção automatizada. Paralelamente a esse objetivo geral,

estabelecem-se também alguns objetivos específicos:

- Mapear os principais aspectos das técnicas de inteligência artificial utilizadas na literatura recente para detecção de sinais depressivos em textos de redes sociais online;
- Avaliar o desempenho de um modelo de inteligência artificial treinado com dados de diferentes redes sociais online na detecção de sinais da depressão, quando aplicado em dados da mesma plataforma e em cenários com dados de plataformas distintas;
- Verificar se modelos treinados com dados agregados de diferentes contextos apresentam resultados consistentes e equilibrados, demonstrando vantagens sobre os modelos especializados em apenas um contexto e gerando um modelo mais robusto.

1.4 Proposta

Diante do exposto, a proposta do trabalho consistiu em conduzir uma investigação dividida em duas frentes complementares. Primeiramente, optou-se por realizar uma investigação exploratória sobre a aplicação de técnicas de Inteligência Artificial na detecção de sinais de depressão. O foco desta etapa é observar os algoritmos e modelos utilizados, as técnicas aplicadas, as fontes de dados coletadas e os resultados alcançados, estabelecendo um comparativo das contribuições e peculiaridades de cada abordagem.

Além disso, a pesquisa incluiu uma análise experimental de natureza *cross-platform*, investigando como modelos treinados com dados de uma rede social se comportavam quando aplicados a uma base de dados de outra rede social. Este estudo permite identificar diferenças de desempenho, possíveis vieses introduzidos pelo contexto específico de cada plataforma e os desafios relacionados à generalização dos modelos.

1.5 Abordagem Metodológica

Para a elaboração desta monografia optou-se por dividir o estudo em duas etapas, sendo a primeira a realização de uma pesquisa de natureza exploratória baseada no protocolo PIOC de revisão. O foco deste estudo é o estado da arte da detecção da manifestação de sinais da depressão em redes sociais online por meio de técnicas de inteligência artificial. Para isso, serão mapeadas as abordagens existentes em estudos prévios através da utilização de uma string de busca pré definida em bibliotecas virtuais de literatura acadêmica. Os resultados recuperados passarão por critérios de inclusão e exclusão, além de uma análise de critérios de qualidade, para montar o escopo analisado.

O objetivo é observar os algoritmos e modelos utilizados ou construídos, as técnicas aplicadas, as fontes e tipos de dados coletados, a língua do corpus e os resultados alcançados. Com base nesse mapeamento, será possível estabelecer um comparativo inicial das contribuições e peculiaridades de cada abordagem, servindo como base para orientar pesquisas futuras e indicar desafios relevantes na aplicação da IA para detecção de depressão online.

Concluída essa etapa, será então conduzido um experimento prático no qual será analisado o desempenho de um modelo de inteligência artificial ao aplicado em diferentes contextos, sendo estes dados extraídos de redes sociais online distintas entre si. Conforme destaca (GIL *et al.*, 2002), esse tipo de pesquisa busca identificar e compreender relações entre variáveis sem que o pesquisador exerça controle direto sobre elas, analisando fenômenos tais como ocorrem na realidade observada, o que se alinha ao objetivo deste estudo.

Para a realização desta etapa, serão coletados corpus de dados open-source já rotulados em categorias de depressão, utilizados no treinamento de uma técnica de inteligência artificial já existente para gerar modelos de detecção especializados em dados de diferentes redes sociais online. Estes modelos então serão testados em diferentes contextos de dados de redes sociais online, para assim serem coletadas métricas de desempenho para posterior análise.

1.6 Organização do trabalho

Este trabalho acadêmico foi organizado em capítulos, cada um com objetivos específicos que orientam o desenvolvimento da pesquisa. O Capítulo 1 apresenta a introdução, incluindo a contextualização, a motivação, o problema, os objetivos e a abordagem metodológica adotada. O Capítulo 2 aborda a fundamentação teórica, com base conceitual sobre redes sociais, transtornos psicológicos, em especial a depressão, inteligência artificial e suas subáreas relevantes, como Processamento de Linguagem Natural e Análise de Sentimentos, além de aspectos éticos relacionados ao uso de dados. O Capítulo 3 apresenta o estudo exploratório, descrevendo seu planejamento, metodologia e principais resultados obtidos a partir da análise da literatura. O Capítulo 4 apresenta o experimento realizado, detalhando seus materiais e métodos, execução, resultados e limitações. Por fim, o Capítulo 5 apresenta as conclusões do trabalho, bem como perspectivas de trabalhos futuros.

2 Fundamentação Teórica

Este capítulo apresenta os conceitos essenciais que sustentam o desenvolvimento deste trabalho, fornecendo a base necessária para compreender o fenômeno investigado e as técnicas utilizadas. Inicialmente, discute-se o papel das redes sociais, abordando suas principais plataformas, sua influência na sociedade e os impactos negativos associados ao seu uso. Em seguida, explora-se o campo dos transtornos de saúde mental, com foco na depressão, destacando seus efeitos sobre o bem-estar e o desempenho cotidiano. Por fim, são introduzidos os conceitos de inteligência artificial, processamento de linguagem natural e análise lexical, áreas que oferecem o suporte técnico para a abordagem computacional de detecção de sinais depressivos em redes sociais, bem como as implicações éticas envolvidas nesse processo.

2.1 Redes Sociais

O ser humano, entendido como um ser social e político desde Aristóteles, estabelece relações que são fundamentais para seu bem-estar e desenvolvimento. Nesse sentido, as redes sociais tornam-se inerentes às relações interpessoais, pois são espaços nos quais as pessoas podem ativamente criar laços, inserir-se em grupos e compartilhar experiências e informações (TAVARES; GOMES, 2022).

Apesar de "mídias sociais" e "redes sociais" serem vistas e, muitas vezes, aplicadas como sinônimos, existe uma diferença em suas definições, a qual é importante considerar. Redes sociais se refere a um termo específico para estruturas de relações e conexões entre perfis, focado na interação direta entre indivíduos e na forma como se organizam. Enquanto isso, mídias sociais é um campo amplo que permite definições mais arbitrárias, desde que envolvam plataformas que permitem a criação, compartilhamento, interação e circulação de conteúdo gerado por usuários, também denominadas "redes sociais online" (LI *et al.*, 2021; WOLFERS *et al.*, 2025).

O conceito de rede se alterou com o decorrer dos anos, partindo de um pressuposto simples de emaranhado material e avançou para a concepção de vínculos, independente da sua natureza de interação e relação entre si. Com a era da informação, surgiu a "rede das redes", a internet. Através dessa tecnologia, conectar pessoas e conceitos independente da distância se tornou algo trivial, aglomerando todos os tipos de comunidade em um único lugar: a Web (EASLEY *et al.*, 2010).

A partir do surgimento da Web 2.0, ambiente que permitiu a colaboração, criação e troca de conteúdo entre quaisquer usuários, foram inauguradas novas possibilidades de interação online em larga escala. A rede social se expandiu do meio físico de interação para o meio virtual, as quais conceituam a "rede social online" ou "rede social virtual", no qual o agrupamento de indivíduos e interesses ganham uma escala todos-para-todos. Dependendo do contexto, uma troca de discussões pública pode alcançar pessoas fora do seu meio e espaço físico, assim como fora do grupo de interesses em que está inserido (TAVARES; GOMES, 2022).

Desta forma, as plataformas sociais se mostraram capazes de extrapolar o campo tecnológico de sua base, a computação, constituindo-se como espaços socioculturais. As redes se tornam mediadoras das relações sociais, afetivas e culturais entre ou com comunidades, atuando como reconfiguradoras de práticas de interação, construção de subjetividades e criação de novos significados (OLIVEIRA *et al.*, 2023).

2.1.1 Principais Redes Online

No mundo atual, marcado pela ampla difusão das redes sociais, cerca de 5,41 bilhões de pessoas utilizam essas plataformas ativamente. Esse número representa quase 70% da população mundial e reflete um crescimento expressivo, mais de 5,5 vezes em relação aos 970 milhões de usuários registrados em 2010. O dado torna-se ainda mais significativo quando comparado ao total de usuários de internet: 94,2% deles estão ativos em alguma rede social (Backlinko Team, 2025).

Sob uma perspectiva de tipos de redes sociais, as plataformas podem ser organizadas conforme as funcionalidades que predominam em sua estrutura. Destacam-se: Redes de Entretenimento ambientes voltados ao lazer digital, como jogos, es-

portes, cinema e viagens, oferecendo experiências interativas e conteúdos recreativos; Redes de Perfilamento espaços orientados à apresentação e ao desenvolvimento da identidade pessoal ou profissional, nos quais os usuários destacam habilidades, objetivos, trajetórias e produções próprias; e Redes Sociais Gerais plataformas de uso amplo que integram conexão social, compartilhamento e recursos multimídia, permitindo interações cotidianas, troca de mensagens e divulgação de diferentes formatos de conteúdo. Essas categorias evidenciam a diversidade de finalidades presentes no ecossistema das mídias sociais (KOUKARAS; TJORTJIS; ROUSIDIS, 2020).

O uso de redes sociais é bastante diversificado, grande parte dos usuários acessa mais de uma plataforma mensalmente. Globalmente, pessoas acima de 16 anos utilizam em média 6,83 redes sociais por mês, enquanto no Brasil essa média é ligeiramente maior, com 8,05 plataformas mensais. As redes sociais mais populares em termos de usuários ativos globais são Facebook, WhatsApp e YouTube, seguidas por Instagram, TikTok, WeChat, Telegram, Messenger e Snapchat (Backlinko Team, 2025).

O perfil demográfico de uso varia conforme a plataforma. Globalmente, a divisão é de 54,6% homens e 45,4% mulheres, sendo que a maioria das redes possui predominância masculina. Uma exceção é o Pinterest, cuja base de usuários é majoritariamente feminina (Backlinko Team, 2025).

Analisando por gerações, observam-se padrões distintos no uso das principais redes sociais e serviços de mensagens. A geração Z (aproximadamente nascidos entre 1997 e 2012) utiliza globalmente predominantemente Instagram (82,8% dos indivíduos), WhatsApp (73,1%) e Facebook (66,6%). A geração X (entre 1965 e 1980) mantém o uso das mesmas plataformas, porém em ordem diferente: Facebook (74,9%), WhatsApp (65,2%) e Instagram (62,7%). Os millennials (entre 1981 e 1996) seguem o mesmo padrão das três principais plataformas em ordem distinta, com Facebook (77,3%), Instagram (74,4%) e WhatsApp (71,9%). Já os baby boomers (entre 1946 e 1964) apresentam uma leve mudança no top 3, mantendo o Facebook (69,3%) e WhatsApp (56,8%), mas destacando-se pelo uso do Facebook Messenger (50,1%), que não aparece como principal nas gerações mais jovens (Global Web Index, 2024).

As principais formas de interação, também reconhecidas como métricas de engajamento dos usuários, variam entre as diferentes redes sociais. Entre as mais recorrentes, destacam-se seis tipos principais: curtidas indicam aprovação ou apreciação de um conteúdo; comentários representam respostas diretas às postagens; compartilhamentos redistribuição do conteúdo a outras redes ou perfis; cliques abrangem tanto o acesso a links externos quanto a reprodução de vídeos; emojis utilizados como reações emocionais alternativas disponíveis em algumas plataformas; e votos manifestados em enquetes ou respostas a postagens interativas (YIP; MAKMOR-BAKRY; CHONG, 2024).

2.1.2 Importância das Redes Sociais Online na Sociedade

Atualmente, grande parte das informações geradas é publicada online, e, conseqüentemente, cada vez mais atividades participativas estão ocorrendo ou sendo coordenadas inteiramente por meio das mídias sociais. Dessa forma, o uso generalizado das Tecnologias da Informação e Comunicação (TICs), como as redes sociais, tem transformado profundamente as estruturas sociais e os modos de comunicação na sociedade. Embora os efeitos negativos do uso excessivo dessas mídias ainda estejam sendo descobertos e estudados, há, por outro lado, uma ampla gama de benefícios proporcionados pela digitalização da informação, entre eles: a redução nos custos de comunicação, o acesso facilitado ao conhecimento, a disponibilidade de ferramentas educacionais e a democratização da criação e do consumo de conteúdo (LYBECK; KOIRANEN; KOIVULA, 2024).

Além disso, pode-se afirmar que um dos principais efeitos das redes sociais é a capacidade de permitir que cidadãos comuns participem ativamente da política, tornando-se formadores de opinião e influenciando outras pessoas de forma significativa, um impacto que dificilmente seria alcançado sem o uso dessas ferramentas. Aqueles que dominam o uso estratégico das redes sociais passam a ter uma vantagem considerável no cenário político-midiático, enquanto aqueles que não as utilizam tendem a enfrentar maiores dificuldades em obter o mesmo alcance. Outro ponto de grande relevância é a centralização das informações quase exclusivamente nessas plataformas, o que as transforma em ferramentas culturais e educacionais de extrema importância, possibilitando um acesso mais amplo e democrático

ao conhecimento (LYBECK; KOIRANEN; KOIVULA, 2024).

Com a pandemia da COVID-19 e as medidas adotadas mundialmente para sua contenção, atividades cotidianas precisaram ser interrompidas, incluindo serviços essenciais como o ensino presencial nas instituições de educação. Diante desse cenário, tornou-se necessário adotar soluções que permitissem a continuidade dessas atividades. As mídias sociais, nesse contexto, assumiram um papel ainda mais central, consolidando-se como ferramentas fundamentais para a vida em sociedade. No campo da educação, foram incorporadas diversas plataformas e redes sociais que possibilitaram aos educadores oferecer ensino a distância por meio de videoconferências e outros sistemas virtuais. Mesmo após o fim da fase crítica da pandemia, esses sistemas mantiveram-se como ferramentas eficazes para a disponibilização de recursos educacionais e informativos aos alunos (CRUZ-RAMIREZ; OLAZA-MAGUIÑA, 2021).

No que diz respeito à população idosa, as mídias sociais podem se mostrar ferramentas extremamente relevantes. Segundo a Teoria da Seleção, Otimização e Compensação (SOC), essas plataformas digitais funcionam como uma estratégia eficaz para superar limitações físicas ou energéticas que acompanham o envelhecimento, permitindo que os idosos mantenham seu engajamento social. A Teoria da Atividade complementa essa perspectiva, ao considerar o engajamento digital como uma forma moderna de participação social, permitindo aos idosos continuarem ativos na sociedade, mesmo diante de barreiras físicas ou geográficas. Já a Teoria da Continuidade sugere que o uso de mídias digitais facilita a preservação de padrões de relacionamento e laços sociais significativos ao longo do tempo (RIBEIRO *et al.*, 2025).

Estas são apenas algumas das inúmeras aplicações relevantes das redes sociais que merecem destaque no contexto contemporâneo. Com a massificação do uso da internet, essas plataformas assumiram um papel central e quase indispensável na vida cotidiana das pessoas, influenciando não apenas a forma como nos comunicamos, mas também como nos relacionamos, consumimos informação, participamos da política e acessamos a educação. Além disso, o impacto cultural das redes sociais vai além da comunicação direta, atuando como agentes de transformação social e inovação, ao impulsionar debates, fomentar movimentos sociais e

democratizar o acesso a conhecimentos e serviços. No entanto, esse papel crucial também impõe desafios complexos, como a necessidade de lidar com a desinformação, a privacidade e o equilíbrio no uso dessas tecnologias, desafios esses que devem ser superados para potencializar os benefícios que elas proporcionam.

2.1.3 Impactos Negativos das Redes Sociais Online

A Internet foi uma ferramenta desenvolvida para o fluxo de informação militar e logo se expandiu para a sociedade, se beneficiando das tecnologias emergentes que a compunham se tornarem de fácil acesso para a população. Consequentemente desenvolvendo esse grande fluxo de dados para troca de interações, o que chamamos de Rede Social Virtual (MATOS; GODINHO, 2024). Em primeira instância, as Redes são uma ferramenta. Seu papel é neutro e, por tal, seus impactos tanto os negativos quanto os positivos, dependem exclusivamente da conduta daqueles que a utilizam (BRITO; MAIA; MILANEZ, 2021). A exposição de conteúdos de desinformação ou de má índole, o borbulho de conflitos e o cyberbullying estão diretamente ligados a condutas negativas dos usuários, tais que impactam negativamente o ambiente que a rede proporciona e aqueles presentes nela (MATOS; GODINHO, 2024).

Ademais, a internet é um ambiente em que a privacidade e segurança estão constantemente em um embate. As informações que navegam na rede são, a princípio, sigilosas e, de acordo com o Marco Civil da Internet, devem ser armazenadas e apenas disponibilizadas em casos de investigação e mandato judicial (Presidência da República do Brasil, 2014). A privacidade das suas atividades e dados deveria ser garantida com essa medida, porém, é uma prática comum entre empresas haver a "compra de dados" sem o consentimento adequado, somando-se ao fato de ataques cibernéticos em brechas de segurança (MATOS; GODINHO, 2024).

Estar conectado na internet e interagir com suas comunidades é estar inserido em uma Rede Social. Apesar de trazer vários benefícios, também existem seus malefícios. Principalmente no uso excessivo, que se torna um percalço crescente ao tê-la presente no dia a dia do cotidiano. Além da sua importância já mencionada, o uso das Redes pode se tornar uma dependência por frequentemente projetar o ideal de vida, suprir carências, causar visibilidade pública a causas próprias e po-

tencializar sentimento de impunidade graças ao anonimato. Quando mencionamos os principais usuários ávidos da rede, os jovens adolescentes, o problema se intensifica (SANTOS; RODRIGUES, 2023). No ano de 2021, foi revelado que a maior faixa etária presente na rede está entre 14 a 25 anos, contabilizando-se 82% dos usuários (BRITO; MAIA; MILANEZ, 2021) e essa faixa engloba principalmente adolescentes e jovens adultos.

A adolescência é uma etapa de amadurecimento humano muito importante para o amadurecimento e crescimento, é um período em que ocorrem muitas mudanças físicas, comportamentais, a construção da sua imagem e reconhecimento como indivíduo inserido na sociedade, com seus próprios valores e decisões. Por ser uma fase de reestruturação e consolidação, é considerada uma idade que contém muita vulnerabilidade social e emocional (SOUZA; TOZATTO, 2024).

Em outra pesquisa de 2021, foram levantados dados que revelam que 27% dos usuários das Redes expõem seus sentimentos e procuram ajuda através de mensagens, sendo que 42% deles estavam na faixa etária de jovens adolescentes (EISENSTEIN, 2023). Com os diversos estímulos gerados pela rede, constante sensação de pertencimento ou aprovação de uma comunidade, somada com uma possibilidade de escape da realidade, os jovens são os mais suscetíveis a gerar dependência e, conseqüentemente, afetar negativamente o desenvolvimento cognitivo e social, impactando diretamente a saúde mental, além das conseqüências físicas como insônia, lesões por esforço repetitivo (LER), problemas de visão, postura, auditivos e até mesmo distúrbios alimentares (MATOS; GODINHO, 2024; SANTOS; RODRIGUES, 2023).

Apesar dos prejuízos poderem ser vistos em vários níveis, o grande enfoque se torna o prejuízo psíquico que se é causado. O verdadeiro impacto negativo ao comentar-se sobre as Redes Sociais Online são o vício, a dependência e conseqüente isolamento e solidão, o desenvolvimento de ansiedade, depressão e baixa autoestima, produtividade e deterioração no bem-estar (MATOS; GODINHO, 2024).

2.2 Transtornos de Saúde Mental

Segundo a Organização Mundial da Saúde (OMS), cerca de uma em cada sete pessoas no mundo vive com algum transtorno mental, condição caracterizada por uma alteração clinicamente significativa na cognição, regulação emocional ou comportamento do indivíduo. Esses transtornos estão geralmente associados a sofrimento psicológico e prejuízos em áreas importantes do funcionamento cotidiano, podendo interromper a vida diária quando não tratados adequadamente. Embora existam formas eficazes de prevenção e tratamento, que envolvem acompanhamento profissional e intervenções terapêuticas, a maioria das pessoas ainda não tem acesso a esses cuidados de maneira adequada (OMS, 2025b).

Há diversos tipos de condições de saúde mental, incluindo transtornos mentais, deficiências psicossociais e outros estados associados ao sofrimento, prejuízo funcional ou risco de autolesão. Entre os principais tipos, destacam-se: transtornos de ansiedade caracterizados por medo e preocupação excessivos; transtorno depressivo, que será abordado em detalhe posteriormente; transtorno bipolar marcado por alternância entre episódios depressivos e maníacos; transtorno de estresse pós-traumático resultante da exposição a eventos traumáticos e caracterizado por reviver o ocorrido, evitar gatilhos e sentir ameaça constante; esquizofrenia envolve distorções graves da percepção e do comportamento, como delírios e alucinações; transtornos alimentares definidos por padrões anormais de alimentação e preocupação excessiva com a forma corporal; transtornos de comportamento disruptivo e dissocial envolvem desobediência persistente, agressividade ou violação de regras sociais; e transtornos do neurodesenvolvimento que surgem na infância e afetam funções intelectuais, motoras, linguísticas e sociais (OMS, 2025b).

2.2.1 Impactos na Educação e na Saúde

Na adolescência, fase marcada pela formação da identidade e pelo rápido crescimento físico, ocorre o início da maioria dos transtornos mentais. Diversos estudos têm relatado um aumento significativo nos transtornos mentais autorrelatados entre adolescentes do mundo ocidental nas últimas duas décadas, os quais exercem efeitos negativos sobre o desenvolvimento e o desempenho escolar. Con-

dições como ansiedade, depressão e TDAH afetam de forma negativa a atenção, o aprendizado e a cognição, estando associadas ao baixo rendimento acadêmico e à evasão escolar (NORDMO *et al.*, 2024).

No contexto universitário, a saúde mental dos estudantes tornou-se uma importante questão de saúde pública no século XXI. Um número crescente de alunos do ensino superior relata sintomas de sofrimento psicológico, que podem afetar suas relações interpessoais, desempenho acadêmico, saúde física e perspectivas futuras. O Healthy Minds Study 2023/2024, realizado nos Estados Unidos, indicou que apenas 38% dos estudantes apresentavam boa saúde mental, enquanto quase metade afirmou ter se sentido tão deprimida a ponto de não conseguir funcionar adequadamente, e 35,1% relataram que a ansiedade prejudicava significativamente seu desempenho acadêmico. Embora baseados em dados norte-americanos, esses resultados refletem uma tendência global, com universidades de diferentes países também registrando aumento nos índices de sofrimento psicológico, quadro agravado pela pandemia de COVID-19 (ROY; BISWAS; SHARMA, 2025).

No que diz respeito ao bem-estar e à saúde, uma revisão sistemática conduzida a partir de uma ampla coleção de artigos provenientes de grandes bases de dados sintetizou evidências de 57 estudos, abrangendo aproximadamente 570 mil participantes. Os resultados revelaram que o uso diário de mídias sociais está associado ao aumento dos níveis de estresse, ansiedade, depressão, solidão e pior qualidade do sono, além de impactar negativamente a autoestima, a imagem corporal e a satisfação com a vida (BEHERA *et al.*, 2025).

Do ponto de vista fisiológico, o uso frequente também se relaciona a ardência ocular, dores nos punhos, pescoço e ombros, entre outros desconfortos. Além disso, foi observado um aumento do sentimento de isolamento e uma redução nas funções executivas e na memória prospectiva. Por fim, o uso problemático das redes sociais mostrou-se associado à menor capacidade de regulação emocional, bem como ao aumento da procrastinação e do estresse percebido (BEHERA *et al.*, 2025).

2.3 Transtorno Depressivo

O transtorno depressivo, ou simplesmente depressão, é um problema de saúde mental frequente caracterizado por um estado persistente de tristeza, desânimo ou pela perda de interesse e prazer em atividades cotidianas por períodos prolongados. Diferente das variações normais de humor, o quadro depressivo afeta significativamente a forma como a pessoa pensa, sente e age, podendo comprometer relacionamentos familiares, sociais e profissionais, adicionalmente gerando dificuldades no ambiente escolar ou de trabalho. Embora qualquer indivíduo possa ser afetado, fatores como experiências traumáticas, abuso, perdas significativas ou situações de estresse intenso aumentam o risco de seu desenvolvimento. Estudos indicam que as mulheres apresentam uma maior prevalência de depressão em comparação aos homens (OMS, 2025a). Além disso, evidências importantes indicam que comportamentos suicidas e agressões podem ser observados em pessoas que sofrem com essa doença (American Psychiatric Association, 2014).

Alguns dos principais sintomas apresentados durante um episódio depressivo incluem: humor persistentemente deprimido, irritabilidade e sensação de vazio, acompanhados da perda de prazer ou interesse em atividades cotidianas. Algumas características adicionais podem ser: dificuldades de concentração, distúrbios do sono, alterações no apetite, fadiga e sentimentos excessivos de culpa ou inutilidade. Diferentemente das flutuações normais de humor, esses sintomas costumam durar a maior parte do dia e caracterizam-se por episódios com duração mínima de duas semanas, embora na maioria dos casos persistam por períodos mais longos. É importante diferenciar a depressão clínica da tristeza ou do luto, que, apesar de causarem sofrimento significativo, geralmente não configuram um transtorno depressivo maior. Esses sintomas afetam profundamente a vida cotidiana, comprometendo o convívio social, o desempenho profissional e o bem-estar emocional. Mesmo que o diagnóstico possa ser feito após um único episódio, o distúrbio frequentemente se manifesta de forma recorrente. Uma forma mais crônica da doença, conhecida como transtorno depressivo persistente, é diagnosticada quando os sintomas se mantêm por pelo menos dois anos em adultos (OMS, 2025a; American Psychiatric Association, 2014).

A condição surge a partir da combinação de múltiplos fatores sociais, psicológicos e biológicos, sendo mais comum em pessoas que passaram por situações adversas, como perdas, traumas ou períodos de grande estresse, e pode, por consequência, provocar diversas outras dificuldades na vida do indivíduo. Além disso, a saúde física exerce grande influência no surgimento da doença, condições como o sedentarismo e o consumo excessivo de álcool são fatores que aumentam o risco não apenas de depressão, mas também de doenças como câncer, diabetes e doenças cardiovasculares. Por sua vez, pessoas que convivem com essas condições de saúde podem desenvolver depressão em decorrência das dificuldades enfrentadas no manejo de suas doenças (OMS, 2025a).

O diagnóstico da depressão deve ser feito por um profissional de saúde, sendo recomendável procurar esses especialistas assim que forem percebidos sinais do transtorno. Existem tratamentos eficazes para lidar com o distúrbio, incluindo intervenções psicológicas e medicamentos, sendo essencial o acompanhamento profissional. As terapias psicológicas são o tratamento recomendado, pois podem ajudar o paciente a desenvolver novas formas de pensar, lidar com dificuldades e se relacionar. Em casos de depressão moderada a grave, pode também se fazer necessário o uso de medicamentos, sempre prescritos por profissionais de saúde, considerando os possíveis efeitos adversos e as preferências individuais do paciente. Antidepressivos não devem ser utilizados em crianças e não são recomendados como primeira opção para adolescentes, que devem receber tratamento com cautela (OMS, 2025a).

As redes sociais, por serem um espaço que contribui com o engajamento, a torna uma ferramenta poderosa para contribuir com pistas sobre a manifestação dos sinais da depressão, podendo destacar indicadores como: a variação de humor dos seus usuários, a atividade e interação social dentro da rede, o conteúdo das postagens e o uso de certos filtros em fotos (KMETTY; BOZSONYI, 2022). Diversas manifestações da depressão podem ser encontradas online, seja em elementos textuais ou não. Por exemplo, é observado que indivíduos depressivos na comunidade do Facebook possuem uma rede de amigos menor, interação pouco através de comentários e curtidas, mas postam e utilizam com frequência expressões negativas, mesmo que apenas o uso delas, não possam significar um sinal de depressão

(KMETTY; BOZSONYI, 2022; SEABROOK *et al.*, 2018).

Entretanto, vale destacar que esses elementos variam de acordo com o ambiente social, linguagem utilizada e cultura. Nem todos os elementos que são indicadores em uma rede específica com um público, por exemplo, ocidental, podem ser os mesmo para a mesma rede com o público oriental. Cabe que estes indicadores sejam investigados para cada contexto aplicado (SEABROOK *et al.*, 2018).

2.4 Inteligência Artificial (IA)

John McCarthy, apontado como o responsável por cunhar o termo "inteligência artificial" em 1956, descreveu o conceito como "a ciência e a engenharia de criar máquinas inteligentes". Embora o termo tenha sido formalizado na década de 1950, as ideias que cercam máquinas inteligentes já circulavam bem antes. Em 1942, o escritor de ficção científica Isaac Asimov, em sua obra atemporal "I, Robot", apresentou reflexões que hoje são consideradas fundamentais para debates sobre a relação entre humanos e máquinas inteligentes e para a ética da IA moderna. Mesmo com essas concepções iniciais e o crescente interesse despertado por elas, ao longo das décadas seguintes o campo da IA experimentou ciclos de grande entusiasmo e períodos de estagnação, os chamados "verões" e "invernos" da inteligência artificial (TOOSI *et al.*, 2021).

O conceito de inteligência é multifacetado e foi apresentado de diversas maneiras, por diferentes pensadores. Mas, neste caso, é possível resumi-la como a capacidade de resolver problemas, adaptar-se ao ambiente e aprender através das situações. Esses fatores são bases para como a Inteligência Artificial funciona. Os sistemas computacionais utilizam-se da sua memória, capacidade de processamento e um algoritmo de aprendizado para realizar as tarefas aos quais foram propostos a realizar, alcançar os resultados e otimizá-los de acordo com experiências passadas. A capacidade de aprendizado permite extrair complexidade e padrões de uma gama de dados, viabilizando as tarefas que antes seriam de difícil ou impossível automação, dado a incapacidade humana de explicar seu conhecimento (DORES, 2018; COZMAN; PLONSKI; NERI, 2021).

Com essa base, é possível inferir que as principais grandes áreas de atu-

ação da IA engloba a participação de jogos, a tradução de idiomas, a solução de problemas e o reconhecimento de padrões (CAMPOS, 2020). Neste presente trabalho, será explorado o campo de aprendizado de máquina para reconhecimento de padrões e o Processamento de Linguagem Natural (PLN), subárea de atuação da IA.

2.5 Processamento de Linguagem Natural

O Processamento de Linguagem Natural (PLN) tem como objetivo permitir a compreensão, interpretação e geração da linguagem humana por máquinas, buscando reduzir a lacuna entre a forma como os humanos se comunicam e a maneira como os computadores processam e compreendem informações textuais e faladas de modo significativo. Essa tecnologia possui uma ampla gama de aplicações, que vão desde assistentes pessoais inteligentes e serviços de tradução automática até sistemas de análise de sentimentos, moderação de conteúdo em redes sociais e outras soluções que exigem interação entre linguagem humana e inteligência artificial (RONGALI, 2025).

2.5.1 Funcionamento e Desafios Técnicos

Para que os computadores processem a linguagem, o texto bruto deve ser representado numericamente. Esse processo inicia-se com a *tokenização*, que segmenta o texto em unidades básicas. Subsequentemente, durante o processo conhecido como *vetorização*, as palavras são convertidas em vetores, que permitem o processamento computacional. Complementarmente, para que haja uma compreensão do significado e contexto, são aplicadas técnicas de *embedding*, responsáveis por projetar essas palavras em um espaço vetorial de alta dimensão, no qual termos semanticamente semelhantes são representados por vetores localizados próximos um do outro geometricamente (JURAFSKY, 2000).

Após a representação vetorial, o modelo da IA passa por um estágio de pré-treinamento massivo, no qual aprende padrões linguísticos, fatos e estruturas de conhecimento a partir de grandes volumes de dados. Entretanto, para que a IA se torne eficaz em domínios ou tarefas específicas utiliza-se o *fine-tuning* (ajuste fino).

Esse processo consiste em treinar o modelo já pré-treinado em um conjunto de dados (corpus) menor e especializado, permitindo que ele se adapte ao contexto de interesse sem a necessidade de um novo aprendizado computacional exaustivo, otimizando tanto o desempenho quanto a precisão nas respostas esperadas (DEVLIN *et al.*, 2019).

Entretanto, a área de PLN enfrenta desafios que variam conforme sua arquitetura e aplicação. Um problema recorrente a todos os sistemas baseados em aprendizado de máquina são os *viéses* (bias). Como os modelos aprendem a partir de grandes volumes de dados que refletem padrões sociais, históricos e culturais, essas IAs podem incorporar e perpetuar preconceitos presentes nestes dados, resultando em decisões automatizadas discriminatórias ou tendenciosas (MEHRABI *et al.*, 2021).

Adicionalmente, no caso de modelos generativos de linguagem (LLMs), frequentemente apresentam o fenômeno da *alucinação*. Diferentemente dos erros de classificação, observados em tarefas de reconhecimento de padrões onde o modelo falha ao atribuir um rótulo correto, a alucinação é uma falha específica de sistemas generativos, no qual o modelo gera e confirma informações factualmente incorretas ou desconexas, decorrente da natureza probabilística da predição de tokens (HUANG *et al.*, 2025).

2.5.2 Principais Desafios Linguísticos e Estruturais

A ambiguidade da linguagem humana é um dos maiores desafios para o Processamento de Linguagem Natural (PLN), podendo ser léxica (quando uma palavra assume significados diferentes conforme o uso), sintática (quando uma mesma frase pode ser lida de maneiras distintas) ou semântica (quando, mesmo após a análise sintática, ainda há ambiguidade, pois uma frase pode expressar ideias diferentes ou conter sentidos figurados). Esses aspectos tornam o domínio da linguagem um enorme desafio para essa tecnologia (RONGALI, 2025).

Outro desafio importante é o fato de a linguagem ser profundamente contextual, tornando essencial compreender em que cenário uma frase é dita para identificar seu significado real de forma eficaz. Já a pragmática refere-se ao uso

da linguagem em situações comunicativas, nas quais o emissor pressupõe certos conhecimentos por parte do ouvinte, como ocorre com a ironia e o sarcasmo, que ultrapassam o sentido literal das palavras empregadas (RONGALI, 2025).

Há ainda uma significativa diversidade cultural e linguística, na qual termos, expressões e até mesmo a forma de escrever e estruturar frases divergem notavelmente entre diferentes idiomas e regiões do mundo. Os padrões sintáticos e semânticos variam de tal forma que expressões comuns em uma língua podem não existir em outra, o mesmo ocorre com o humor, a ironia e a polidez. Em razão disso, alguns modelos de PLN enfrentam dificuldades ao processar linguagens de diferentes culturas, já que a maioria deles é desenvolvida com foco no inglês, podendo apresentar desempenho limitado em outros contextos linguísticos e culturais (RONGALI, 2025).

2.6 Análise Lexical

Análise lexical é o estudo do significado das palavras e das relações entre elas. Em vez de tratar as palavras apenas como sequências de letras, a análise lexical busca compreender seus sentidos, semelhanças e conexões. Por exemplo, palavras podem ser sinônimas quando apresentam significados praticamente idênticos, como "carro" e "automóvel" ou podem ser relacionadas por associação, como "café" e "xícara", que não são similares em significado, mas estão ligadas pelo uso cotidiano (JURAFSKY; MARTIN, 2026).

Essa análise também considera aspectos emocionais e subjetivos das palavras, conhecidos como conotações, que envolvem sentimentos positivos ou negativos. Palavras como "feliz" carregam conotação positiva, enquanto "triste" carrega conotação negativa. Dessa forma, a análise lexical permite mapear o significado das palavras em múltiplas dimensões, sendo fundamental para tarefas computacionais como identificação de sentimentos, interpretação de textos e processamento de linguagem natural (JURAFSKY; MARTIN, 2026).

2.7 Detecção de Sinais Depressivos via Técnicas de IA

A Inteligência Artificial é a integração de várias tecnologias que, com o uso de diversificados algoritmos, são capazes de fazer a máquina "aprender" e corrigir seus erros até se alcançar refinamento e precisão. Independente da técnica por trás do modelo, utilizando-se desta capacidade de aprendizado e identificação de padrões, o uso da IA no campo da saúde mental e psiquiatria tem o potencial benéfico de auxiliar e aprimorar abordagens como, principalmente, a detecção de sinais do transtorno, a discriminação deste em comparação a outras possíveis doenças e até mesmo prever a eficácia do tratamento dado o perfil dos dados analisados (JÚLIO, 2024).

Além disso, a Inteligência Artificial, com sua alta capacidade de processamento de volume de dados, é capaz de perceber os padrões específicos de cada paciente e comparar sua gama de dados de maneira rápida e automática, permitindo o auxílio aos profissionais da área quanto ao aprimoramento dos seus tratamentos, personalizando a abordagem de caso a caso, assim como apresenta habilidade para potencializar a prevenção dos transtornos ou mesmo apontar um possível diagnóstico através da interpretação dos resultados e vislumbres de correlações complexas difíceis de se perceber (SILVA *et al.*, 2025).

No geral, treinar uma IA envolve um conjunto de tarefas metódicas como de coleta e tratamento dos dados, que demandam tempo, e a sua qualidade é de suma importância para garantir seu desempenho. Esse "corpus" ou dataset gerado que irá dar base ao funcionamento depois de se escolher o modelo de abordagem mais factível ao caso de aplicação e, após o devido tratamento e treinamento com base nos dados, ainda é necessário que haja avaliação da precisão, confirmando-se se os esforços e os dados coletados trouxeram resultados satisfatórios para uso real (SAIWA, 2024). Por tal, é necessário o esforço coletivo de especialistas nesse quesito. Se feita corretamente, o desempenho do modelo aplicado a diagnóstico pode se comparar ao de um clínico experiente. Com a objetividade e imparcialidade da máquina, se tornam soluções viáveis para triagem em comparação com método convencionais (GOH *et al.*, 2025).

Quando falamos sobre Detecção de Transtornos, como a depressão, os mo-

delos ainda podem variar, mas os amplamente usados na área envolvem principalmente técnicas de aprendizagem com Rede Neurais Profundas, Máquina de Vetores de Suporte (SVM), Naive Bayes (NB), com auxílio de Transformers e Visão Computacional (JÚLIO, 2024; GOH *et al.*, 2025). A Visão Computacional é a ideal para lidar com dados multi-modais enquanto os Transformers são modelos com o melhor desempenho ao lidar com dados textuais (GOH *et al.*, 2025).

2.7.1 Treinamento a partir de Dados de Redes Sociais Online

Com o permear do uso das tecnologias no cotidiano e a criação da Web, o número de pessoas que se conectam online, consomem e criam conteúdo é cada vez maior. As mídias sociais são a principal fonte de geração de dados, graças a alta interação dos usuários que trocam informações e experiências de maneira instantânea. A agrupação desse volume enorme de dados advindos das Redes Sociais é o que chamamos de Big Social Data. Com ela, adquirir informações relevantes sobre os usuários ou um grupo estudado é facilitado (SILVEIRA, 2016).

No que diz respeito a Inteligência Artificial e a Detecção de Depressão, o que é disponibilizado de informação online inclui emoções, sentimentos, pensamentos, humor e opiniões pessoais, estas, que incluem sintomas da depressão. Os dados das Redes Sociais, além de uma rica fonte, é ampla, permitindo suprir a grande demanda que é reunir dados suficientes para treinamento (RODRIGUES *et al.*, 2024), além de suprir a dificuldade dos profissionais da área avaliar tantos dados em pouco tempo (GOH *et al.*, 2025).

2.7.2 Implicações Éticas

O uso da IA na área da saúde carrega consigo várias implicações éticas que devem ser levadas em conta ao introduzir a tecnologia para pesquisa ou para uso real. Primeiramente, o dataset precisa respeitar a privacidade e a segurança dos usuários dos quais forem coletados e, em caso de dados de manipulação direta com acompanhamento de profissionais, o comprometimento com o consentimento do uso é essencial, somada com responsabilidade médica para com a aplicação direta. Além disso, é crucial entender que a Inteligência Artificial não deve ser negli-

genciada e usada de maneira completamente autônoma. A máquina não substitui o diagnóstico ou avaliação médica, mas sim é uma ferramenta para potencializar resultados e tomadas de decisão. Sua aplicação demasiada e fora do escopo projetado também trás impactos negativos para a sociedade, os quais não podem ser ignorados ao se tratar de uma condição humana fundamental: a saúde e o bem estar. Por tal, o avanço desta tecnologia acaba por ser limitada por fatores como confiança mútua dos provedores do serviço e dos pacientes (GOMES, 2025).

2.8 Considerações Finais

Diante da discussão realizada neste capítulo, fica evidente como a combinação do alcance das Redes Sociais, com sua alta geração de dados, e técnicas emergentes de Inteligência Artificial, com sua alta velocidade de processamento e capacidade de tomada de decisão, podem contribuir para a melhoria exponencial na área de saúde mental, caso seja levado em conta as questões éticas e seja aplicada corretamente. Apesar disso, ressalva-se que as mídias digitais são brandas e se divergem em vários aspectos, assim como as abordagens para intervenção e detecção de depressão.

Dessa forma, faz-se necessário entender os métodos por trás de cada estudo, avaliar suas contribuições e desafios para que seja possível otimizar o uso da ferramenta de IA em cada proposta e necessidade médica, visto que a abordagem tem o pressuposto de variar de acordo com o tipo de interação e a forma como aplica a ferramenta: detecção, prevenção, acompanhamento ou personalização de atendimento. Por tal, será realizada uma análise das propostas existentes, de modo a identificar tecnologias, escopo e lacunas, assim como levantar o impacto da heterogeneidade das redes no treinamento e performance geral.

Com base nos elementos apresentados ao longo da fundamentação deste capítulo, torna-se possível estabelecer uma compreensão mais consistente do cenário estudado, o que fornece suporte conceitual para a condução das etapas subsequentes desta pesquisa.

3 O Estudo Exploratório

Neste capítulo, apresenta-se o estudo exploratório realizado com o objetivo de analisar a literatura mais recente acerca do uso de técnicas de Inteligência Artificial na detecção de sinais de depressão em mensagens de redes sociais online. Será detalhado inicialmente os procedimentos metodológicos, seguido da sumarização dos trabalhos selecionados e uma breve discussão e análise dos achados mais relevantes.

3.1 Planejamento

A concepção para a execução deste levantamento da literatura foi elaborada com o objetivo de coletar e sumarizar as principais técnicas aplicadas no ambiente computacional, com o uso de IA, para a detecção de sinais da depressão em mensagens que circulam em ambientes digitais, especificamente através das redes sociais online, tendo como base o processo de revisão sistemática da literatura, Utilizando-se como ponto de partida a metodologia PIOC, uma adaptação da metodologia PICO originalmente proposta por Richardson et al. (1995) para formulação de perguntas clínicas em revisões sistemáticas (RICHARDSON *et al.*, 1995). Enquanto o PICO estrutura a pergunta de pesquisa em quatro elementos: População, Intervenção, Comparação e Resultado (Outcome), o PIOC substitui o elemento "Comparação" por "Contexto", visando melhor adequação a estudos exploratórios e de mapeamento da literatura em áreas como a Computação. Na Tabela 1 são apresentadas as respostas definidas para cada elemento da estratégia.

Population	Mensagens em redes sociais que apresentam sinais de depressão.
Intervention	Mapeamento de abordagens para detecção.
Outcome	Compilação de metodologias de IA para análise de sinais.
Context	Redes sociais online.

Tabela 1 – Definição dos elementos da estratégia PIOC.


Dessa forma, além de fornecer um panorama geral dos artigos quanto a: (1) o método utilizado, (2) a rede social online empregada para treinamento, (3) o formato de dados adotado, (4) a língua na qual a solução foi aplicada, (5) se o modelo é generalista ou específico para depressão e (6) se há distinção entre diferentes estágios ou graus da condição, foram elaboradas questões de pesquisa a serem respondidas ao final deste estudo, como observado na Tabela 2.

ID	Questão de Pesquisa
QP1	Quais são as abordagens computacionais mais utilizadas?
QP2	Qual é a fonte de dados predominante?
QP3	Qual formato de dados é mais utilizado?

Tabela 2 – Questões de Pesquisa (QP) definidas.

3.2 Abordagem Metodológica

Figura 1 – Fluxo do processo metodológico para seleção dos artigos



Fonte: Elaborado pelos autores.

Nesta etapa, descreve-se detalhadamente o processo adotado para a obtenção e seleção dos artigos utilizados na condução do estudo exploratório. A Figura 1 apresenta uma síntese do fluxo metodológico, evidenciando, de forma estruturada, as etapas seguidas ao longo do processo.

A coleta dos trabalhos para esse estudo foi realizada através de três bibliotecas virtuais: SBC OpenLib (SOL), PubMed e IEEE Xplore. A escolha da biblioteca da Sociedade Brasileira da Computação (SBC) foi importante para a extração de artigos em português, contribuindo para complementar a perspectiva internacional. Além disso, a adição da PubMed permitiu acesso a estudos com enfoque na área

da saúde, enquanto a IEEE Xplore se destaca como uma base ampla e consolidada, com grande relevância para o campo da computação.


Com a consolidação das bibliotecas, seguindo uma metodologia a par de uma revisão sistemática da literatura, foi-se definida palavras-chave referentes ao foco de pesquisa, utilizadas para a construção da seguinte string de busca, a ser consultada nas bibliotecas:

("depression" OR "major depressive disorder") AND ("social media" OR "online community" OR "social network") AND ("Artificial Intelligence" OR "machine learning") AND ("identification" OR "detection" OR "finding")

Para a definição da estratégia de busca, foram selecionadas palavras-chave alinhadas ao problema de pesquisa, organizadas na forma de uma string estruturada para recuperar estudos relevantes. Essa construção considerou termos diretamente relacionados à depressão, ao contexto de redes sociais e às técnicas de Inteligência Artificial, além de expressões voltadas à tarefa de detecção.

Após a definição da estratégia de busca e a aplicação da string nas bases de dados selecionadas, aplicada sob uma restrição temporal ao período entre 2022 e 2025, dado o aumento exponencial de pesquisas sobre o tópico. Essa etapa teve como objetivo garantir a atualidade e relevância dos estudos considerados, alinhando-os com os avanços mais recentes da área. Como resultado desse processo, obteve-se um total de 494 trabalhos pré-selecionados, sendo 424 provenientes da plataforma IEEE Xplore, 59 da PubMed e 11 da SBC, conforme a distribuição demonstrada na Figura 2.

Figura 2 – Distribuição de artigos por plataforma



Fonte: Elaborado pelos autores.

Em seguida, após a retirada de trabalhos duplicados, para efetuar a seleção dos artigos que propunham desenvolver as perguntas propostas nesse trabalho foram decididos critérios de inclusão e exclusão, os quais podem ser visto na Tabela 3.

Crítérios de Inclusão	Crítérios de Exclusão
Artigos disponíveis para acesso completo	Estudos que se distanciam do tópico de detecção de depressão
Artigos publicados em português e inglês	Trabalhos sem aplicação computacional prática
Estudos primários	Estudos que não utilizam base de dados provenientes de redes sociais online
Trabalhos publicados entre 2022 e 2025	Estudos Comparativos


Tabela 3 – Critérios de Inclusão e Exclusão definidos.

Tais critérios de exclusão adotados foram definidos com o intuito de garantir maior aderência aos objetivos desta pesquisa. Em particular, a exclusão de estudos comparativos e de revisão justifica-se pela busca por trabalhos que apresentem propostas originais com aplicação direta. Da mesma forma, optou-se por conside-

rar apenas estudos que utilizam bases de dados provenientes de redes sociais e que possuam aplicação computacional prática, uma vez que o foco deste trabalho está na análise de abordagens aplicadas e voltadas à detecção da depressão nestes contextos. Por fim, foram desconsiderados estudos que se distanciam do tema central, a fim de manter a consistência e relevância do conjunto final de artigos analisados.

Após a aplicação dos critérios de exclusão, foram selecionados 172 trabalhos. A proporção de artigos aceitos, agrupados por base, pode ser observada na Figura 3. Posteriormente, esses trabalhos foram submetidos à avaliação com base em critérios de qualidade previamente estabelecidos, ilustrados na Tabela 4.

Figura 3 – Proporção de artigos aceitos por base



Fonte: Elaborado pelos autores.

ID	Critério de Qualidade
CQ1	O método/técnica é bem definido(a)?
CQ2	A origem dos dados é documentada?
CQ3	O dataset está disponível?
CQ4	São abordadas questões éticas?
CQ5	O estudo apresenta alguma novidade em comparação a estudos anteriores?


Tabela 4 – Critérios de Qualidade (CQ) definidos.

Esses critérios foram definidos com o objetivo de estabelecer uma camada

adicional de validação, assegurando que os trabalhos selecionados estejam alinhados de forma mais rigorosa aos objetivos da pesquisa, além de apresentarem maior qualidade metodológica e científica. A identificação clara da fonte de dados, especialmente quando acessível, contribui para uma compreensão mais aprofundada do estudo, possibilitando inclusive a extração de insights que não estão explicitamente descritos no artigo. Da mesma forma, a descrição detalhada do método ou técnica adotada favorece a reprodutibilidade e o entendimento do modelo proposto. A consideração de aspectos éticos evidencia a maturidade e a responsabilidade científica da pesquisa, enquanto a presença de elementos de novidade em relação a estudos anteriores reforça a relevância e a contribuição do trabalho para o avanço da área.

A aplicação desses critérios resultou em um processo adicional de refinamento do conjunto de estudos. Cada trabalho foi avaliado com base nas questões propostas, sendo atribuídos três níveis de classificação: sim, parcialmente e não, correspondentes às pontuações 1, 0.5 e 0, respectivamente. Foram desconsiderados os estudos que obtiveram pontuação igual ou inferior a 3, garantindo a seleção de pesquisas com maior rigor e consistência. Ao término dessa etapa, obteve-se um total de **114 artigos**, os quais foram submetidos a uma leitura parcial, com o objetivo de viabilizar a extração sistemática dos dados necessários para responder às questões de pesquisa. Os resultados decorrentes dessa análise são apresentados na seção seguinte. A Figura 4 ilustra a variação do número de artigos ao longo das etapas do processo de seleção.

Figura 4 – Variação do número de artigos ao longo das etapas do processo de seleção




Fonte: Elaborado pelos autores.

3.3 Resultados e Discussão

Primeiramente, vale ressaltar que a aplicação da string de busca resultou em uma distribuição inicial crescente de artigos ao longo do período analisado. Observa-se, conforme ilustrado na Figura 5, um aumento significativo no número de publicações entre os anos de 2022 e 2025, passando de 104 no primeiro para 242 no último ano do recorte analisado. Esse comportamento evidencia que a área de pesquisa encontra-se em expansão e apresenta crescente interesse da comunidade científica. Tal tendência reforça a relevância do tema investigado, indicando não apenas sua atualidade, mas também a intensificação de estudos voltados à aplicação de técnicas computacionais para a detecção da depressão em contextos digitais, especialmente em redes sociais.

Figura 5 – Distribuição de trabalhos por ano



Fonte: Elaborado pelos autores.

Diante desse cenário de crescimento na produção científica, esta seção tem como objetivo apresentar e discutir os principais resultados identificados nos artigos analisados, buscando responder às questões de pesquisa propostas.

3.3.1 Resultados das Questões de Pesquisa

Nesta subseção, são apresentados os resultados da análise em um nível mais geral e sintético, destacando os principais achados em relação às questões de pesquisa definidas, com ênfase nas abordagens, técnicas e tendências identificadas na literatura.

Os dados completos, contendo o detalhamento de todos os trabalhos incluídos e das informações extraídas, encontram-se disponíveis em repositório público na plataforma Github¹, permitindo uma visão abrangente e aprofundada do material analisado.


Abordagens computacionais

As principais abordagens computacionais empregadas nos trabalhos analisados abrangem diversas técnicas, destacando-se principalmente o BERT (*Bidirectional Encoder Representations from Transformers*), em seguida, os modelos de redes neurais artificiais, como CNN (*Convolutional Neural Network*), LSTM (*Long Short-Term Memory*) e MLP (*Multilayer Perceptron*), bem como técnicas clássicas

¹ Disponível em: <<https://github.com/Guerco/Depress-IA>>.

de aprendizado de máquina, incluindo SVM (*Support Vector Machine*), RF (*Random Forest*), KNN (*K-Nearest Neighbors*), Regressão Logística (*Logistic Regression*) e Naive Bayes. A Figura 6 apresenta a distribuição do número de artigos para os dez métodos mais utilizados nos estudos analisados.

Figura 6 – Distribuição de métodos presentes nos trabalhos



Fonte: Elaborado pelos autores.

Além dos métodos mais frequentes, destacam-se também modelos baseados em *Transformers*, especialmente os derivados do BERT, bem como outras abordagens de aprendizado de máquina e redes neurais. Para uma melhor organização e análise dos resultados, essas técnicas são apresentadas a seguir de forma agrupada em três categorias principais: técnicas clássicas de *machine learning*, modelos baseados em *redes neurais profundas* e modelos baseados em *Transformers*.

Técnicas de Machine Learning: Machine Learning é uma subárea da inteligência artificial que desenvolve algoritmos capazes de aprender automaticamente a partir de dados, identificando padrões e relações sem a necessidade de programação explícita para cada tarefa. Com base nesse aprendizado, esses modelos conseguem fazer previsões, tomar decisões e generalizar conhecimentos para novos dados, sendo amplamente utilizados em aplicações como sistemas de recomendação, reconhecimento de imagens, análise de dados e assistentes virtuais, também

sendo capaz de detectar padrões em textos, como apor exemplo a identificação de sinais de linguagem associados à depressão (BERGMANN, 2024).

Nos principais estudos analisados, destacam-se técnicas clássicas de machine learning como SVM (Support Vector Machine), Random Forest (Floresta Aleatória), KNN (K-Nearest Neighbors), Naive Bayes (Modelo ingênuo de Bayes), Logistic Regression (Regressão Logística), Linear Regression (Regressão Linear) e Decision Tree (Árvore de Decisão), amplamente utilizadas por sua simplicidade, interpretabilidade e bom desempenho em diferentes cenários.

Além dessas, também aparecem métodos como AdaBoost (Adaptive Boosting), Extra Trees (Extremely Randomized Trees), Gradient Boosting (GB/GBR Gradient Boosting Regressor), LightGBM (Light Gradient Boosting Machine) e XGBoost (Extreme Gradient Boosting), que representam abordagens baseadas em ensemble learning (aprendizado por conjuntos), combinando múltiplos modelos para maior robustez preditiva.

Modelos baseados em Redes Neurais: Rede neural profunda é uma arquitetura de inteligência artificial composta por múltiplas camadas de processamento que aprendem, de forma automática, representações cada vez mais abstratas dos dados, cada camada refinando o que aprendeu da anterior através do algoritmo de backpropagation. É essa profundidade de camadas que permite ao modelo descobrir padrões complexos em grandes volumes de dados, sendo a base tecnológica por trás de avanços em reconhecimento de fala, visão computacional, e até áreas como genômica (LECUN; BENGIO; HINTON, 2015).

As redes neurais podem ser usadas para diversos objetivos e, por tal, podemos dividi-las de acordo com as tarefas propostas e a natureza dos dados de entrada. Ao se tratar principalmente de dados de imagem e visão computacional, destaca-se a Rede Neural Convolucional (CNN), entre as quais incluem modelos como o VGG16, ResNet50, Cascade CNN, EfficientNetB0. Enquanto isso, ao se tratar de dados sequenciais, podemos destacar modelos de Rede Neural Recorrente (RNN) como LSTM (Long Short-Term Memory), GRU (Gated Recurrent Unit), TS-LSTM (Time Series Long Short-Term Memory), bem como suas variantes bidirecionais, como BiLSTM e BiGRU. Por fim, podemos destacar modelos mais espe-

cíficos como o GCN (Graph Convolutional Network), que opera sobre dados estruturados em grafos, e o CLIP (Contrastive LanguageImage Pretraining), um modelo multimodal que combina elementos da imagem com o texto fornecido, aprendendo representações conjuntas.


Modelos baseados em Transformers: Transformer é um modelo de inteligência artificial que revolucionou o processamento de linguagem ao abandonar completamente as redes neurais recorrentes, que até então dominavam as tarefas de tradução e modelagem de sequências. Em vez de processar o texto palavra por palavra de forma sequencial, o Transformer funciona inteiramente através de mecanismos de atenção, que permitem ao modelo identificar relações e dependências entre qualquer parte do texto independentemente da distância entre elas, tornando o treinamento muito mais rápido e paralelizável (VASWANI *et al.*, 2023).

Dentre os principais modelos baseados no *Transformer*, destaca-se o BERT (Bidirectional Encoder Representations from Transformers), bem como alguns de seus derivados, como ALBERT (A Lite BERT), RoBERTa (Robustly Optimized BERT Approach), SBERT (Sentence-BERT) e DeBERTa (Decoding-enhanced BERT with Disentangled Attention). Além disso, também se observam os modelos de grande porte baseados em *Transformers*, conhecidos como LLMs (Large Language Models), como LLaMA (Large Language Model Meta AI) e Mistral (Model with Sparse Transformer Layers).

Fontes de Dados

Do ponto de vista das principais plataformas de redes sociais utilizadas como fonte de dados nos estudos, destacam-se, sobretudo, o Twitter e o Reddit, ambas majoritariamente centradas em conteúdo textual e em relatos de usuários. Em seguida, aparece o Sina Weibo, plataforma chinesa com funcionamento semelhante ao Twitter, seguido pelo Facebook e, posteriormente, o YouTube, uma plataforma predominantemente voltada para conteúdos em vídeo. A Figura 7 apresenta a proporção e a quantidade de trabalhos que utilizam essas redes como fonte de dados.

Figura 7 – Distribuição de plataformas presentes nos trabalhos



Fonte: Elaborado pelos autores.

Além dessas principais plataformas, também são observadas outras redes com menor recorrência nos estudos, como a Everytime, uma plataforma voltada para universitários sul-coreanos, presente em dois trabalhos. Também aparecem, de forma pontual, redes como TikTok e Instagram, além de plataformas de blogs pessoais, como Bloggang e Blogspot, bem como Bilibili, VK e Storylog, sendo que todas essas últimas foram utilizadas em apenas um único artigo cada.


Destaca-se a predominância de plataformas voltadas à publicação de depoimentos textuais, o que é coerente com o fato de que a maioria dos trabalhos analisados trata da classificação de dados textuais, tema que será abordado a seguir. Além disso, ressalta-se a forte presença do Twitter e do Reddit, impulsionada não apenas por sua popularidade, mas também pela facilidade de extração de dados e pela ampla disponibilidade de repositórios e bases públicas (KARAMI *et al.*, 2020; Columbia University Libraries, n.d.).

Formato de Dados

Por fim, conforme mencionado anteriormente, o formato de dados predominante nos estudos é o textual, presente em aproximadamente 95% (109 de 114) dos trabalhos analisados e amplamente utilizado como base para modelos de clas-

sificação de depressão. Em seguida, aparecem os formatos de imagem, áudio e vídeo, em menor proporção. A Figura 8 apresenta esta distribuição.

Figura 8 – Distribuição de formatos presentes nos trabalhos



Fonte: Elaborado pelos autores.

Observou-se também que, dos 114 trabalhos analisados, 91 eram puramente textuais e os demais apresentavam caráter multimodal. Além disso, apenas dois dos estudos textuais explicitavam o uso de emojis. Em adição aos formatos de dados mais frequentemente reportados, alguns trabalhos utilizaram informações de estatísticas comportamentais e de padrões de uso dos indivíduos investigados, bem como dados de localização via GPS e dados fisiológicos (MUTHU; ELAKKIA; TAMILSELVI, 2025).


Outros estudos também recorreram a informações obtidas por meio de questionários, como o PHQ-9 (Patient Health Questionnaire-9), um instrumento amplamente utilizado para identificar e avaliar a intensidade de sintomas depressivos (ANGSKUN; TIPPRASERT; ANGSKUN, 2022). Um dos trabalhos, ainda, utilizou em complemento dados do MBTI, um modelo que categoriza pessoas em diferentes perfis de personalidade com base em preferências psicológicas, geralmente usado em contextos de autoavaliação (PRADNYANA *et al.*, 2025).

Informações Complementares Extraídas dos Estudos

Além das questões de pesquisa, outras informações também foram extraídas dos artigos. Essas informações incluem: em qual língua a solução foi aplicada, se o modelo é generalista ou específico para detecção de depressão e se há distinção entre diferentes níveis de gravidade da condição. Nesta seção, são apresentados os resultados obtidos para esses aspectos.

Primeiramente, no que se refere aos idiomas dos dados, observa-se que a grande maioria dos estudos utiliza o inglês, o que se explica por sua ampla predominância na internet, pela disponibilidade de bases de dados nesse idioma e pelo próprio critério de seleção de trabalhos, que favoreceu publicações em inglês. Em seguida, com certa distância, aparece o chinês, idioma amplamente falado e também com presença relevante em bases de dados acadêmicas. Na sequência, identificam-se idiomas como bengali, falado principalmente em Bangladesh e em algumas regiões da Índia, português, tailandês, urdu, que é utilizado principalmente no Paquistão e novamente em partes da Índia, e o coreano. A distribuição de tais idiomas é apontada na Figura 9.

Figura 9 – Distribuição de idiomas presentes nos trabalhos




Fonte: Elaborado pelos autores.

Além dos idiomas mais frequentes, também foram identificados árabe, russo, indonésio e japonês, cada um presente em apenas um dos trabalhos analisados.

Agora, no que se refere aos tipos de transtornos classificados pelos trabalhos, 88 estudos apresentaram foco exclusivo na classificação de depressão, enquanto os demais abordaram mais de uma condição. Entre esses, o transtorno mais frequentemente associado é a ansiedade, seguido por ideação suicida e estresse psicológico. Em menor frequência, aparecem também a bipolaridade e transtornos de personalidade, como o transtorno de personalidade borderline. Outros transtornos foram identificados em uma quantidade reduzida de estudos, incluindo o TEPT (Transtorno de Estresse Pós-Traumático) e o TDAH (Transtorno do Déficit de Atenção e Hiperatividade). A seguir, apresenta-se a distribuição dessas condições adicionais, conforme ilustrado na Figura 10.

Figura 10 – Distribuição das condições de saúde abordadas nos trabalhos




Fonte: Elaborado pelos autores.

Destaca-se também que um dos trabalhos teve foco específico em depressão pós-parto, uma forma de depressão que pode ocorrer em mulheres no período seguinte ao nascimento de um bebê (LAMHARMECH *et al.*, 2025). Outro estudo apresentou uma abordagem mais generalista, voltada à classificação de múltiplas diferentes condições de saúde mental além da depressão. Nesse caso, o modelo

também contempla diferentes tipos de ansiedade, incluindo ansiedade generalizada e ansiedade social, além de transtornos por abuso de substâncias, transtorno do espectro autista, esquizofrenia e bipolaridade, entre outros (AKIB *et al.*, 2025).

Por fim, observa-se que a grande maioria dos estudos realiza uma classificação binária dos transtornos, indicando apenas a presença ou ausência de sinais associados a determinada condição. Em menor proporção, alguns trabalhos adotam abordagens mais granulares, realizando uma classificação em níveis de gravidade, como depressão leve, moderada ou severa. A Figura 11 ilustra essa distribuição.

Figura 11 – Distribuição dos tipos de classificação nos trabalhos



Fonte: Elaborado pelos autores.

3.3.2 Estudos de Abordagens Distintivas

Nesta seção, serão destacados trabalhos que apresentam abordagens metodológicas e/ou conceituais distintivas no contexto da literatura analisada, com o objetivo de evidenciar contribuições particularmente relevantes, inovadoras ou representativas das diferentes formas de investigação do tema.

No estudo *Deep Learning-Based Detection of Depression and Suicidal Tendencies in Social Media Data with Feature Selection*, Baydili, Tasci e Tasci (2025) propõem uma abordagem baseada em votação majoritária (*Majority Voting*), na qual o texto é submetido a diversos modelos de classificação simultaneamente. Nessa metodologia, a predição final é definida pelo consenso da maioria, técnica que visa aumentar a estabilidade dos resultados e que se diferencia das tendências predominantes na literatura analisada (BAYDILI; TASCI; TASCI, 2025).

Já no trabalho *Revealing Depression Through Social Media via Adaptive Gated Cross-Modal Fusion Augmented With Insights From Personality Traits*, Pradnyana et al. (2025) apresentam uma metodologia inovadora ao integrar não apenas textos e imagens, mas também traços de personalidade baseados no indicador Myers-Briggs (MBTI). A abordagem utiliza um mecanismo de fusão adaptativa que permite combinar esses diferentes tipos de dados, evidenciando que a inclusão das características psicológicas individuais proporciona *insights* fundamentais para a detecção da depressão. Essa estratégia se mostra promissora ao demonstrar que a análise do comportamento expressivo, quando aliada ao perfil de personalidade do usuário, eleva consideravelmente a precisão dos modelos propostos (PRADNYANA et al., 2025).

No trabalho *MentalNet: Heterogeneous Graph Representation for Early Depression Detection*, Mihov et al. (2022) propõem uma abordagem baseada em redes de grafos heterogêneos para a detecção precoce da depressão. Diferente de métodos focados apenas no conteúdo textual, a estrutura *MentalNet* modela as interações dos usuários (como respostas e menções) para capturar a influência de seus círculos sociais. Ao representar essas conexões e diferenciar o nível de intimidade nas interações, o estudo demonstra que o contexto relacional do usuário oferece informações cruciais para identificar padrões depressivos (MIHOV et al., 2022).

No estudo *DeepMindWatch: A Multi Modal AI Framework for Early Detection of Depression and Anxiety from Digital Bio Markers*, Muthu, Elakkia e Tamilselvi (2025) introduzem uma abordagem multimodal que se diferencia pela utilização de biomarcadores digitais heterogêneos. Além dos dados de redes sociais, a estrutura integra registros clínicos e, principalmente, dados de sensoriamento passivo coletados via aplicativos móveis. Essa combinação de fontes permite uma análise contínua e menos invasiva, possibilitando a identificação de indicadores de depressão e ansiedade com uma antecedência significativa em relação ao diagnóstico clínico tradicional (MUTHU; ELAKKIA; TAMILSELVI, 2025).

Enquanto isso, no trabalho *Domain Knowledge Enhanced Text Mining for Identifying Mental Disorder Patterns*, Shahabikargar et al. (2022) utilizam a abordagem de Base do Conhecimento, organizando o conhecimento clínico, estruturado

ou não, a fim de auxiliar a identificar os transtornos mentais com um aprendizado de máquina fracamente supervisionado. Esse domínio parte da técnica de Análise Cognitiva, que combina o poder de processamento de dados com o conhecimento cognitivo humano, mapeando fatores de risco, características relacionadas e características de suporte relacionadas a determinado transtorno. Dessa forma, ao utilizar uma API para classificar as instâncias de dados textuais relacionadas aos sintomas ou entradas mapeadas no domínio, combinada a um algoritmo de aprendizado de máquina, é possível criar um classificador binário sobre um transtorno específico, que neste caso, foi a depressão. Além de ser uma técnica pouco vista, o artigo também contribui mostrando os conceitos e características indicativas do transtorno que foram extraídas (SHAHABIKARGAR *et al.*, 2022).

Já no estudo *Decoding Linguistic Nuances in Mental Health Text Classification Using Expressive Narrative Stories*, Tang *et al.* (2024) focam em explorar o domínio textual de Narrativas Expressivas, uma prática de descrição sobre vivências e sua reação a elas, expondo pensamentos e sentimentos sobre situações do dia a dia, buscando contribuir para a descoberta ou fortalecimento de nuances linguísticas atreladas a transtornos mentais para o aprimoramento das técnicas de Processamento de Linguagem Natural e Aprendizado de Máquina. Ao utilizar esta prática, foi observado que o modelo MentalBERT, focado em saúde mental, desempenhou mal ao perder correlações com palavras-chaves específicas sobre o tópico que normalmente não são evidentes em relatos narrativos, enquanto o modelo BERT manteve bons resultados e interpretou as nuances sutis. Essa técnica revelou que é essencial que os modelos utilizados na detecção sejam treinados para compreensão linguística e não apenas na observação de palavras-chaves (TANG *et al.*, 2024).

Analogamente, apesar do trabalho *The Expression of Happiness in Social Media of Individuals Reporting Depression* de Bucur *et al.* (2024) não se propor a detectar depressão, ele se compromete a entender como pessoas depressivas expressam sua felicidade, dando ênfase que o uso de palavras positivas, relacionadas a felicidade, ou vice-versa não necessariamente indicam realmente um momento feliz, impossibilitando uma prática de análise de sentimentos trazer resultados verdadeiramente satisfatórios. Além disso, é avaliado como o gênero afeta

essas expressões e momentos de felicidade (BUCUR *et al.*, 2024).

Por fim, o estudo *Depression Detection on Social Media With User Network and Engagement Features Using Machine Learning Methods* de Liaw e Chua (2022) propõe uma abordagem de dados textuais misturados com o engajamento e interação do usuário na rede. Seu principal destaque se dá em descobertas em como os *likes* (curtidas) em publicações relacionadas a depressão de outros usuários se tornou um fator mais revelador sobre a condição da pessoa avaliada do que seus próprios relatos e postagens (LIAW; CHUA, 2022).

De forma geral, os estudos apresentados nesta subseção ilustram a diversidade de abordagens metodológicas e conceituais empregadas na detecção de transtornos mentais a partir de dados digitais. As diferentes estratégias evidenciam a natureza multidisciplinar do problema e a variedade de caminhos explorados na literatura recente. Ressalta-se que esses trabalhos não esgotam as possibilidades existentes, mas representam exemplos relevantes identificados durante o estudo exploratório.

3.4 Considerações do Estudo

Com a realização desta pesquisa, observou-se o crescente interesse em utilizar tecnologias de inteligência artificial na área da saúde ao longo dos anos, com modelos e técnicas evoluindo constantemente e o surgimento de novas vertentes, características e abordagens para o tema. Em resposta às questões de pesquisa propostas, apesar da predominância no uso de técnicas de aprendizado profundo, com destaque especial para tecnologias baseadas em Transformers, como o BERT, o uso de metodologias híbridas, que encadeiam diferentes modelos de aprendizado de máquina para interagir entre si explorando suas complementaridades, bem como a incorporação da leitura de dados multimodais, têm se tornado mais frequentes, havendo ainda amplo espaço para exploração. Além disso, constatou-se que os dados textuais continuam sendo a principal fonte de informação, embora haja um aumento significativo no uso de dados multimodais, incorporando imagens, interações sociais e até biomarcadores digitais.

Adicionalmente, mesmo com o aumento de trabalhos sobre a detecção au-

tomática de depressão nas redes online, ainda é uma tarefa árdua identificar qual metodologia ou modelo apresenta melhor desempenho em um panorama geral. Observou-se que fatores como a origem dos dados, idioma, formato, forma de tratamento e as técnicas de pré-processamento são altamente diversos e impactam diretamente no resultado final. Portanto, os estudos analisados demonstraram que a área tem avançado não apenas em termos de desempenho preditivo, mas também na incorporação de perspectivas distintivas, incluindo aspectos comportamentais, sociais e psicológicos. Abordagens inovadoras, como o uso de traços de personalidade, análise de redes de interação e integração com conhecimento clínico, indicam que a detecção de depressão vai além do conteúdo textual isolado, exigindo modelos capazes de capturar nuances complexas do comportamento humano.

Por fim, conclui-se que, apesar da heterogeneidade cada vez mais frequente, os estudos convergem para um mesmo objetivo. A escolha de técnicas está frequentemente relacionada ao escopo do projeto, bem como às questões éticas envolvidas em cada trabalho. Tanto as vertentes de generalização quanto as focadas na especialização de modelos ainda possuem espaço para melhorias, seja na descoberta de novas variáveis relevantes, seja na otimização do uso ou custo computacional. Dessa forma, o campo permanece aberto para avanços significativos, especialmente no desenvolvimento de soluções mais robustas, interpretáveis e eticamente responsáveis.

4 O Experimento

Neste capítulo, é apresentado o experimento e análise da aplicação dos modelos de IA treinados para detecção de sinais da depressão a partir de dados retirados de diferentes redes sociais online. Será detalhada a questão de pesquisa norteadora e as hipóteses nula e alternativa, assim como a abordagem metodológica da pesquisa e o ambiente de teste e aplicação utilizado, discutindo-se os resultados obtidos.

4.1 Planejamento

É fato que cada plataforma de mídia social possui suas próprias peculiaridades, incluindo modos de interação, público e padrões de vocabulário. Dessa forma, cada rede configura um ecossistema específico, com características próprias e variações internas na forma de bolhas e subecossistemas (KHALID; SRINIVASAN, 2020). Esse cenário pode representar um importante desafio para o treinamento de modelos de IA, introduzindo vieses e padrões que nem sempre são aplicáveis aos usuários de outras plataformas. Tal limitação torna-se especialmente relevante em aplicações relacionadas à saúde, devido à sensibilidade do tema e à necessidade de maior precisão na detecção de indícios de problemas graves, como a depressão.

Com isso em mente, este estudo tem como objetivo realizar um experimento *cross-plataforma*, onde se analisa o desempenho dos modelos treinados com dados de plataformas de redes sociais online ao serem expostos a contextos diferentes daqueles utilizados em seu treinamento. Em complemento, busca-se também avaliar a viabilidade e a pertinência de modelos mais generalistas, treinados com dados de múltiplas redes sociais online, averiguando se tais modelos trazem de fato vantagens para a tarefa de classificação.

Desta forma, para a condução deste experimento, foi definida como Questão de Pesquisa (QP) norteadora: "*A mudança de domínio impacta negativamente na*

performance do modelo?", a partir da qual foram formuladas as hipóteses:

- **Hipótese Nula:** Não há impacto perceptível na mudança de domínio e
- **Hipótese Alternativa:** A mudança de domínio afeta o desempenho do modelo.

Para avaliar a eficácia do modelo frente à mudança de domínio, foram definidas as variáveis independentes, dependentes, de controle e as métricas de avaliação, garantindo a padronização do experimento. As variáveis independentes são compostas pela combinação das bases de dados, alternadas entre plataforma de origem e destino, enquanto as variáveis dependentes são representadas pelos indicadores de performance.

Quanto as métricas de avaliação de desempenho, por se tratar de um algoritmo de classificação binária, ou seja, que provêm apenas com resultados entre 0 (negativo) e 1 (positivo) dentro do contexto do domínio, é possível medir sua eficácia através de quatro resultados: Verdadeiro Positivo (VP), Falso Positivo (FP), Verdadeiro Negativo (VN) e Falso Negativo (FN). Dessa forma, se propõe que o modelo seja avaliado através da Acurácia, Sensibilidade (Recall), Precisão e F1-Score (RAINIO; TEUHO; KLÉN, 2024).

A Acurácia, uma métrica de análise geral, é responsável por definir a porcentagem de indivíduos que foram classificados corretamente pelo modelo, seja como positivo ou negativo. Por outro lado, a Precisão demonstra, em porcentagem, quantos indivíduos foram classificados corretamente com Verdadeiro Positivo e, acompanhada pela Sensibilidade (Recall), que é responsável por determinar a porcentagem de quantos indivíduos com positivo foram realmente rotulados com um Verdadeiro Positivo, são métricas que revelam de maneira mais precisa o comportamento observado pelo algoritmo. Por isso, a F1-Score é a junção harmônica da Precisão e do Recall (MILLER *et al.*, 2024; RAINIO; TEUHO; KLÉN, 2024). As equações a seguir formalizam o cálculo dessas métricas:

$$\text{Acurácia} = \frac{\text{VP} + \text{VN}}{\text{VP} + \text{VN} + \text{FP} + \text{FN}}$$

$$\text{Precisão} = \frac{\text{VP}}{\text{VP} + \text{FP}}$$

$$\text{Recall} = \frac{\text{VP}}{\text{VP} + \text{FN}}$$

$$\text{F1-Score} = \frac{2 \cdot \text{Precisão} \cdot \text{Recall}}{\text{Precisão} + \text{Recall}}$$

Para fins de análise em saúde mental, priorizou-se o *F1-Score* como métrica principal, por balancear a precisão, ou seja, a capacidade de evitar falsos positivos, e o *Recall*, a capacidade de detectar todos os casos de risco, minimizando-se falsos negativos. A Tabela 5 sumariza as variáveis e métricas adotadas.

Categoria	Descrição
Variáveis Independentes	Domínio de origem (treino) e domínio de destino (teste).
Variáveis Dependentes	Desempenho do modelo mensurado pelas métricas de classificação.
Variáveis de Controle	Arquitetura, hiperparâmetros de treinamento e procedimentos de pré-processamento.
Métricas de Avaliação	Acurácia, Precisão, <i>Recall</i> e <i>F1-Score</i> .

Tabela 5 – Variáveis e métricas utilizadas no experimento.

Por fim, foram definidos cenários experimentais para analisar o impacto da mudança de domínio no desempenho dos modelos, considerando avaliações na mesma plataforma, entre plataformas distintas e com a combinação das bases de dados, além da adição de uma base de dados proveniente de uma terceira plataforma como uma variável complementar de controle e validação dos resultados encontrados. Os cenários elaborados são apresentados na Tabela 6.

ID	Descrição do Cenário
Cenário 1	Modelos (A, B e AB) x Base A
Cenário 2	Modelos (A, B e AB) x Base B
Cenário 3	Modelos (A, B e AB) x Base AB
Cenário 4	Modelos (A, B e AB) x Base C

Tabela 6 – Descrição dos cenários de treinamento e teste.

4.2 Materiais e Métodos

Nesta etapa, descreve-se detalhadamente o protocolo adotado para a obtenção e seleção dos recursos utilizados na condução do experimento, incluindo as bases de dados empregadas e o modelo adotado para o treinamento de fine-tuning.

4.2.1 Bases de Dados

A princípio, procurou-se obter as bases de dados necessárias com o auxílio do trabalho de Bucur e colaboradores, que compila datasets utilizados em diversos estudos de detecção de depressão em redes sociais online, categorizando-os de acordo com nível de acesso, plataforma, idioma, estratégia e formato de classificação dos textos extraídos, além da quantidade de dados coletados (BUCUR *et al.*, 2025). Priorizou-se a seleção de bases provenientes das plataformas Reddit e X (antigo Twitter), por serem as mais recorrentes nos trabalhos abordados na etapa do Estudo Exploratório. Para isso, foram definidos os critérios apresentados na Tabela 7.

ID	Critério de Seleção
CS1	Base de dados de acesso aberto (<i>open-source</i>)
CS2	Idioma inglês
CS3	Dados provenientes de apenas uma rede social
CS4	Quantidade de dados superior a mil instâncias
CS5	Dados de usuários não identificados

Tabela 7 – Critérios de seleção utilizados para a coleta das bases de dados.

A aplicação dos critérios na seleção das bases possibilitou a escolha de duas bases provenientes da plataforma Reddit, uma com aproximadamente 3,5 mil registros (NASEEM *et al.*, 2022) e outra com cerca de 16 mil registros (KAYALVIZHI; THENMOZHI, 2022), as quais foram combinadas para compor um único dataset referente à plataforma.

Entretanto, para as demais redes sociais online, não foi possível identificar, dentre as bases de dados levantadas, uma que atendesse a todos os critérios estabelecidos, com especial dificuldade na obtenção de bases de dados de acesso livre. Dessa forma, optou-se como alternativa pela seleção de uma base de dados aberta disponibilizada na plataforma Kaggle, com dados extraídos do X. Assim, foi escolhida a base Mental Health Social Media, com aproximadamente 20 mil registros, a qual também foi utilizada em alguns dos trabalhos analisados na etapa do Estudo Exploratório (INFAMOUSCODER, 2022).

Ambas as bases de dados do Reddit possuem foco na identificação da severidade da depressão. Na Tabela 8, são apresentados exemplos de mensagens categorizadas em cada nível de severidade, extraídos das bases utilizadas no experimento.

Grau	Mensagem
Mínimo	“Nevermind, turning it up loud. Drown everything else out. Bump. Bump. Bump.”
Leve	“I’m exhausted from just continuing to go to work. God I’m so tired... (...) But I know I’m getting happier, I am happy most days.”
Moderado	“i need someone, i feel so alone and empty.”
Severo	“When Prozac no longer helps”

Tabela 8 – Exemplos de mensagens por nível de severidade da depressão.

Na base de dados desenvolvida por NASEEM *et al.* (2022), os autores reanotaram um conjunto de postagens do Reddit previamente rotulado de forma binária, categorizando cada post em quatro níveis de severidade (mínimo, leve, moderado e severo) com base no esquema clínico *Depressive Disorder Annotation* (DDA), desenvolvido a partir de seis instrumentos clínicos de referência, como o DSM-5 e o PHQ-9. Entretanto, os autores não especificam no trabalho os critérios textuais utilizados para diferenciar cada nível de severidade (NASEEM *et al.*, 2022).

Por sua vez, a base desenvolvida por KAYALVIZHI; THENMOZHI (2022), os dados foram coletados diretamente de subreddits relacionados a saúde mental por

meio da API PRAW e anotados manualmente por dois especialistas de domínio em três níveis de severidade (não deprimido, moderadamente deprimido e severamente deprimido). Os autores definiram diretrizes específicas para cada categoria: postagens classificadas como não deprimidas tratam de tópicos irrelevantes ou sentimentos momentâneos; as moderadamente deprimidas refletem oscilações de humor, mas ainda demonstram esperança; e as severamente deprimidas expressam múltiplos transtornos ou histórico de tentativas de suicídio (KAYALVIZHI; THENMOZHI, 2022).

Já a base de dados do X possui anotação binária, focada apenas na presença ou ausência de depressão. Nesta base não há um detalhamento sobre o processo de coleta ou dos critérios para categorização, tampouco uma descrição do processo de anotação realizado (INFAMOUSCODER, 2022). Na Tabela 9, são apresentados exemplos de mensagens classificadas em ambas categorias.

Depressão	Mensagem
Não	“Me and my brother are teaching our mom how to play 8 ball lmaoo.”
Sim	“I’m so depressed that when I wake up from sleep, I don’t want to face the day.”

Tabela 9 – Exemplos de mensagens presentes na base do Twitter.

Por último, a base de dados complementar utilizada na aplicação do Cenário 4 foi proveniente da plataforma Facebook, oriunda do trabalho Identificação de Sintomas de Depressão por Dados de Mídias Sociais: Aplicando Design Science Research para Desenvolver um Modelo de Classificação (FILHO; SILVA; OLIVEIRA, 2024). Esta base de dados possui anotação binária e é composta por 1944 registros. A seleção desta base teve como objetivo a aplicação dos modelos treinados em um dataset totalmente desvinculado dos dados utilizados no treinamento.

Plataforma	Total de dados	Classificação	Papel
Reddit	~3,5 mil	Severidade	Treinamento e testes
Reddit	~16 mil	Severidade	Treinamento e testes
X (Twitter)	~20 mil	Binária	Treinamento e testes
Facebook	1944	Binária	Apenas testes

Tabela 10 – Resumo das bases de dados utilizadas nos experimentos.

4.2.1.1 Caracterização das Bases

Também é pertinente abordar algumas características das bases de dados utilizadas, de modo a possibilitar uma análise mais fundamentada dos resultados obtidos no experimento. Nesta seção, são apresentadas algumas informações estatísticas e estruturais referentes aos dados de cada base.

Para isso, foi realizado um pré-processamento textual nas bases de dados, removendo elementos que poderiam introduzir ruídos nas análises, como emojis, URLs e indicadores de retweets presentes na base do Twitter. Além disso, utilizou-se também uma versão agrupada da base Reddit, contendo os dados provenientes das diferentes fontes obtidas.

Tamanho dos textos: Uma das primeiras métricas relevantes a serem analisadas é o tamanho médio dos textos presentes nas bases de dados. A Tabela 11 apresenta as médias de palavras e caracteres, tanto de forma geral quanto separadas por classe.

Base	Palavras			Caracteres		
	Não Depressão	Depressão	Geral	ND	D	GER
Reddit	99.66	166.45	142.46	520.13	861.13	738.65
Twitter	11.32	11.94	11.63	67.80	70.10	68.95

Tabela 11 – Médias Aproximadas de Palavras e Caracteres por Base

Os resultados obtidos estão alinhados com o comportamento esperado das

plataformas analisadas. A base do X apresentou médias significativamente menores de caracteres (≈ 69) e palavras (≈ 12) quando comparada à base do Reddit (≈ 739 caracteres e ≈ 142 palavras). Esse comportamento é coerente com a natureza das plataformas, uma vez que o X é voltado para publicações curtas e objetivas, enquanto o Reddit favorece textos mais extensos, descritivos e narrativos.

É interessante observar também que, na base Reddit, há uma diferença considerável entre as médias dos textos com depressão e não depressão, passando de aproximadamente 520 caracteres para 861 nos textos com depressão, e de cerca de 100 palavras para 166, o que pode sugerir que os relatos depressivos tendem a ser mais pessoais, introspectivos e detalhados, consequentemente mais extensos. Em contrapartida, esse padrão não se repete na base do X (Twitter), na qual ambas as classes apresentam médias bastante semelhantes de palavras e caracteres, possivelmente em decorrência da limitação estrutural e do caráter mais objetivo das postagens na plataforma.

Análise Lexical: Em seguida, foi realizada uma análise lexical dos textos categorizados como depressivos por meio da ferramenta **LIWC**, capaz de capturar indicadores relacionados a estados sociais, emocionais e psicológicos a partir da linguagem utilizada pelos indivíduos. A partir das métricas extraídas e da análise das médias obtidas para cada base de dados, foi possível identificar informações relevantes e obter uma compreensão mais aprofundada sobre as características linguísticas e comportamentais das comunidades analisadas (BOYD *et al.*, 2022).


Na Tabela 12 e na Figura 12, podem ser observadas as medidas sumárias referentes a informações mais gerais dos textos analisados, apresentando uma visão mais abrangente sobre suas principais características linguísticas e psicológicas. As métricas analisadas são: *Analytic*, que descreve o grau de formalidade e lógica dos textos, com métricas maiores demonstrando uma comunicação fria e menores uma comunicação amigável; *Clout*, que apresenta o nível de confiança ou autoridade social demonstrada no seu nível de fala, neste caso, métricas menores exibem uma comunicação mais insegura ou humilde; *Authentic*, mede o quanto o autor é honesto e espontâneo, com pontuações baixas indicando cautela em como se expressam; E por fim *Tone*, que reflete a valência emocional do texto, com valores menores de 50 indicando tons afetivos negativos (Pennebaker Conglomerates,

Inc., 2022).

Base	Analytic	Clout	Authentic	Tone
Reddit	16.69	8.67	88.45	21.56
Twitter	46.32	47.50	55.71	52.36

Tabela 12 – Métricas Gerais (Médias)

Figura 12 – Métricas Gerais (Médias)



Fonte: Elaborado pelos autores.

No que diz respeito a estas características gerais dos textos, pode-se observar, na Figura 12, diferenças significativas entre as plataformas analisadas. Em relação à métrica *Authentic*, os textos do Reddit apresentaram valores médios consideravelmente superiores aos do X (Twitter), com 88,45 e 55,71, respectivamente, indicando uma maior tendência a um estilo de escrita mais pessoal e subjetivo.

Já para a métrica *Tone*, observou-se que o Reddit apresentou média de aproximadamente 21,56, enquanto o Twitter apresentou 52,36, sugerindo que os textos provenientes do Reddit tendem a apresentar um tom mais negativo, ao passo que os do Twitter se mostram relativamente mais neutros.


Em relação às métricas *Analytic* e *Clout*, o Twitter apresentou médias superiores quando comparado ao Reddit, sendo aproximadamente 46,32 contra 16,69 para *Analytic* e 47,50 contra 8,67 para *Clout*, evidenciando que os textos do Twitter apresentavam um nível maior de pensamento analítico e maior nível de confiança na escrita, enquanto o Reddit predominou com textos mais pessoais e emocionais, refletindo estilos de comunicação distintos entre as plataformas.

Por outro lado, na Tabela 13 e na Figura 13 são apresentadas as frequências relativas (percentuais) de palavras classificadas em categorias específicas da ferramenta **LIWC**, relacionadas principalmente a emoções e condições mentais. Nesse contexto, *tone_pos* e *tone_neg* medem o equilíbrio entre o uso de palavras positivas e negativas no discurso; *emotion* resume as variáveis *emo_pos* e *emo_neg*, que detalham a proporção de palavras que indicam satisfação ou sofrimento emocional; enquanto *emo_anx* reflete a preocupação ou nervosismo, *emo_anger* a raiva ou hostilidade, e *emo_sad* a tristeza ou luto capturados no uso léxico; por fim, a métrica *mental* indica o grau de esforço mental e introspecção presente na escrita, representados por meio de palavras reflexivas (BOYD *et al.*, 2022; Pennebaker Conglomerates, Inc., 2022).

Tabela 13 – Aspectos Emocionais e Mentais (Médios)

Base	tone_pos	tone_neg	emotion	emo_pos	emo_neg	emo_anx	emo_anger	emo_sad	mental
Reddit	3.1	4.7	4.2	1.0	3.0	0.4	0.4	1.2	1.1
Twitter	5.0	3.9	4.3	1.6	2.4	0.3	0.3	1.2	1.9

Figura 13 – Aspectos Emocionais e Mentais (Médios)



Fonte: Elaborado pelos autores.

A partir da análise dos resultados apresentados, observa-se inicialmente que a base Reddit apresenta uma média maior de palavras em tom negativo (*tone_neg*), enquanto o Twitter apresenta uma média maior para palavras de tom positivo (*tone_pos*), o que está alinhado com o comportamento observado no tom médio das mensagens.

No que diz respeito à quantidade geral de palavras emocionais (*emotion*), ambas as plataformas apresentaram valores semelhantes, 4,16 (Reddit) e 4,28 (Twitter). Entretanto, observa-se novamente que o Reddit apresenta uma maior proporção de palavras de emoção negativa (*emo_neg*) em comparação ao Twitter, enquanto este último, apesar de também apresentar maior presença de tom negativo, possui maior proporção de palavras de emoção positiva (*emo_pos*) em relação ao Reddit.

De forma mais específica, observa-se que, para palavras relacionadas à ansiedade (*emo_anx*), os valores são 0,43 para o Reddit e 0,34 para o Twitter; para raiva (*emo_anger*), 0,41 e 0,29, respectivamente; e para tristeza (*emo_sad*), observam-se valores praticamente equivalentes entre as plataformas, sendo 1,23 e 1,22.

Por fim, o Twitter apresenta uma média maior de palavras relacionadas a processos mentais e saúde psicológica (*mental*), com valor de 1,89, superior aos 1,06

capacidade de compreensão contextual dos textos, além de sua natureza de código aberto (DEVLIN *et al.*, 2019). Com isso em mente, definiu-se a utilização do modelo RoBERTa, uma versão aprimorada do BERT que propõe ajustes em seu processo de treinamento, incluindo a remoção da etapa de Predição da Próxima Sentença (NSP), presente no modelo original. Tais modificações permitiram a obtenção de resultados superiores em diversas tarefas de processamento de linguagem natural, motivando sua adoção neste trabalho (LIU *et al.*, 2019).

Embora o RoBERTa apresente maior demanda computacional em comparação ao BERT devido às otimizações introduzidas em seu processo de treinamento, seu desempenho superior em diversas tarefas de processamento de linguagem natural justifica sua utilização neste trabalho. Dessa forma, considerando sua capacidade de capturar relações contextuais complexas nos textos e os resultados observados na literatura, o modelo foi selecionado para a realização dos experimentos, sendo utilizado por meio de sua implementação disponibilizada na plataforma Hugging Face (FACEBOOKAI, 2026).

Para a realização do treinamento, dos testes e da coleta das métricas de desempenho, foi desenvolvido um notebook em Python no formato *Jupyter Notebook* (.ipynb), aplicado no ambiente Google Colab. A execução dos experimentos contou com acesso aos recursos computacionais disponibilizados pela plataforma, incluindo GPU Nvidia T4, 12 GB de memória RAM e TPU v5e-1. A configuração e execução do processo de *fine-tuning* do modelo RoBERTa, bem como a avaliação dos resultados obtidos, foram realizadas por meio da API *Trainer*, disponibilizada pela biblioteca Transformers do Hugging Face (FACE, 2026). O código fonte desenvolvido na condução do experimento encontra-se no repositório público disponível na plataforma Github¹.

4.3 Execução do Experimento

Após a etapa de definição e obtenção das bases de dados, do modelo e da ferramenta utilizada no experimento, iniciou-se a fase de execução, começando

¹ Disponível em: <<https://github.com/Guerco/Depress-IA>>.

pelo carregamento das bases na plataforma e seguindo para o pré-processamento dos dados.

4.3.1 Pré-Processamento

Nesta etapa, foram realizados tratamentos em ambas as bases de dados com o objetivo de padronizar os dados e equilibrar as bases para o experimento. Esse processo será descrito a seguir.


Limpeza de Ruídos Textuais e Padronização: Para todas as bases do experimento, aplicou-se uma rotina uniforme de limpeza do conteúdo textual das mensagens. Esse processo consistiu na remoção de URLs/links, menções a usuários (@), indicadores de retuítes (RT) nos dados do X e exclusão dos emojis por meio da biblioteca *emoji*. O caractere de hashtag (#) foi removido, preservando-se a palavra-chave associada. Adicionalmente, o texto foi convertido integralmente para letras minúsculas (*lowercase*), os múltiplos espaços em branco foram normalizados e os registros nulos ou inválidos foram eliminados.

Bases Reddit: Após o carregamento no notebook, as duas bases foram combinadas em um único dataset com 20.185 registros. Em seguida, realizou-se uma limpeza dos dados agregados, removendo colunas vazias provavelmente inseridas por engano durante o desenvolvimento da base.

Na sequência, procedeu-se à padronização dos valores para focar na presença ou não da depressão, e não na severidade como as bases focavam originalmente. Para unificar os critérios, as classes mild, moderate e severe foram transformadas no grupo 1 (presença de depressão), enquanto minimum e not depression foram reagrupadas como 0 (ausência de depressão).

Verificou-se então um desbalanceamento entre as classes: 12.935 registros para classe 1 (depressão) e 7.250 para classe 0 (não depressão), proporção ilustrada pela Figura 16, o que poderia introduzir viés no modelo treinado. Para mitigar esse problema, aplicou-se o método *RandomUnderSampler*, reduzindo aleatoriamente os registros da classe 1 ao mesmo número da classe 0, evitando assim a criação de dados sintéticos ou a duplicação de exemplos para balancear as classes.

Figura 16 – Distribuição das classes antes do balanceamento da base do Reddit




Fonte: Elaborado pelos autores.

Base X (Twitter): Já a base de dados do X já havia sido construída com rótulos binários, indicando ausência ou presença de depressão. Além disso, a base encontrava-se previamente balanceada. No entanto, foi aplicada a técnica de *RandomUnderSampler* com outro objetivo: como a base do X possuía uma quantidade de registros superior à base do Reddit, foi necessário reduzir seu tamanho para que o experimento se mantivesse mais equilibrado. Dessa forma, utilizou-se o método apenas para ajustar ambas as classes para 7.250 registros, assim como realizado na base do Reddit.

Base Facebook: Quanto a base de dados do Facebook, além da etapa de limpeza aplicada a todas as bases, foi necessário, devido à presença de rótulos próprios em sua estrutura original, realizar o mapeamento e a conversão das variáveis categóricas para o formato numérico binário (0 e 1), por meio da técnica *LabelEncoder*, adequando-as ao padrão de classes estabelecido. E, apesar de seus dados apresentarem uma distribuição também desbalanceada, composta por aproximadamente 96% do total de 1.944 registros caracterizados como depressivos (Figura 17), não foi realizado um procedimento de balanceamento, uma vez que tal base será utilizada apenas de forma complementar e estritamente para o teste dos modelos treinados pelas demais bases.

Figura 17 – Distribuição de dados no dataset do Facebook



Fonte: Elaborado pelos autores.

Base Mista: Por fim, foi construída uma base de dados mesclada, integrando amostras provenientes tanto do Reddit quanto do X, com o objetivo de permitir a análise conjunta das duas fontes sob um mesmo protocolo experimental. Para garantir equilíbrio entre as plataformas e entre as classes, realizou-se uma amostragem aleatória estratificada, novamente utilizando o *RandomUnderSampler*.

Dessa forma, foram selecionados 7.250 registros de cada base (Reddit e X), preservando a proporcionalidade entre as classes. Em seguida, dentro de cada uma das fontes, manteve-se o balanceamento entre textos depressivos e não depressivos, resultando em 3.625 registros para cada subgrupo (Reddit depressivo, Reddit não depressivo, X depressivo e X não depressivo).

Essa estratégia assegura que a base final não apresente viés nem em relação às classes nem em relação à origem dos dados, permitindo uma comparação mais justa e controlada no treinamento e avaliação dos modelos.

Ambas as Bases: Após o tratamento inicial dos dados, ambas as bases foram convertidas para o formato Dataset, compatível com a biblioteca Hugging Face Datasets. Em seguida, realizou-se a divisão dos dados em dois subconjuntos, treino e teste, adotando-se a proporção de 80% para treinamento e 20% para avaliação, para as bases utilizadas no treinamento dos modelos (Bases Twitter, Reddit e Mista). Na base de dados mesclada, adicionalmente, foi preservada a proporção

nalidade de 50% entre as origens dos dados (Reddit e X) em ambos os conjuntos, de forma a garantir equilíbrio entre as fontes tanto no treino quanto no teste. Essa separação teve como objetivo permitir a validação do desempenho do modelo em dados não utilizados durante o treinamento.

Na sequência, realizou-se a tokenização do corpo das mensagens utilizando o tokenizer do modelo RoBERTa-base. Nesse processo, os textos foram convertidos em tokens compatíveis com o modelo e padronizados por meio de técnicas de padding e truncamento, estabelecendo um limite máximo de 128 tokens por entrada. Essa etapa foi necessária para adequar os dados ao formato esperado pelo modelo durante o treinamento e a inferência. Ressalta-se que o foco do experimento está na análise do impacto da mudança de domínio entre as bases, e não no desenvolvimento do modelo mais otimizado possível, portanto optou-se por um pré-processamento mais simples e padronizado, priorizando a consistência metodológica e o equilíbrio entre as bases e os procedimentos aplicados.

Ao final da etapa de pré-processamento, todas as bases passaram a possuir uma estrutura padronizada, contendo os campos descritos na Tabela 14.

Campo	Conteúdo
text	Corpo das mensagens tokenizado
label	Indicação da presença ou ausência de depressão (0/1)

Tabela 14 – Campos presentes nas bases após o pré-processamento.

4.3.2 Treinamento dos Modelos

Após a etapa de preparação dos datasets e a padronização dos seus dados, cada um dos modelos propostos: Modelo Reddit, Modelo X (Twitter) e Modelo Misto (Reddit e X) foram submetidos aos mesmos hiperparâmetros de treinamento para fine-tuning, que podem ser visualizados na Tabela 15.

Parâmetro	Valor
<code>learning_rate</code>	1×10^{-5}
<code>per_device_train_batch_size</code>	8
<code>per_device_eval_batch_size</code>	8
<code>gradient_accumulation_steps</code>	2
<code>num_train_epochs</code>	4
<code>weight_decay</code>	0.1
<code>warmup_ratio</code>	0.1
<code>label_smoothing_factor</code>	0.1

Tabela 15 – Hiperparâmetros utilizados para o treinamento do modelo.

Levando-se em consideração a tarefa proposta de detecção de sinais de depressão a partir de textos das redes sociais online, os hiperparâmetros foram baseados no benchmarks RACE (LIU *et al.*, 2019), ideal para extração de contexto, ajustados criteriosamente para evitar rápido overfitting do modelo as bases de dados deste trabalho. Além disso, para a simulação de um `batch_size` de 16, foi-se acrescentado o parâmetro `gradient_accumulation_steps` igual a 2.

Adicionalmente, o fine-tuning do RoBERTa para cada um dos datasets foi ajustado para ser interrompido automaticamente caso houvesse a detecção de estagnação do aprendizado sem apresentar evolução em suas métricas com o uso do `callback` `EarlyStoppingCallback` (Hugging Face, 2026) com `early_stopping_patience` igual a 2, salvando-se, no final do processamento, o modelo com melhor F1 entre as épocas.

4.3.3 Resultados

Com o treinamento dos três modelos propostos concluído, cada um deles foi submetido a teste em quatro datasets de redes sociais online distintas, sendo eles categorizados como Dataset Reddit, Dataset X, Dataset Misto (Reddit e X) e Dataset Facebook. Os resultados de acordo com as métricas de desempenho selecionadas podem ser observados nesta seção.

Na Tabela 16 e na Figura 18 são apresentados os resultados para as métricas coletadas na execução dos testes na base de dados do Reddit.

Conforme pode ser observado, o Modelo Misto teve o maior desempenho geral, superando o Modelo Reddit que foi treinado no próprio dataset de teste, como demonstrado principalmente pelo seu F1. A exceção observada nos resultados é quanto a alta taxa de Recall do Modelo X (Twitter) que, conforme apurado nas métricas Recall Com Depressão (Classe 1) e Recall Sem Depressão (Classe 0), é possível inferir que o Modelo treinado no X, validou grande parte do dataset como positivo para depressão, havendo muitos Falsos Positivos.


Dataset Reddit

Modelo	Acurácia	F1	Precisão	Recall
Reddit	0,798966	0,814154	0,756965	0,880690
X	0,567586	0,691437	0,537490	0,968966
Misto	0,856552	0,859079	0,844208	0,874483

Modelo	Prec. Com Dep.	Prec. Sem Dep.	Rec. Com Dep.	Rec. Sem Dep.
Reddit	0,76	0,86	0,88	0,72
X	0,54	0,84	0,97	0,17
Misto	0,84	0,87	0,87	0,84

Tabela 16 – Métricas de desempenho para o Dataset Reddit: Métricas Gerais (acima) e Específicas (abaixo).

Figura 18 – Gráfico das Métricas dos Modelos no Dataset Reddit



Fonte: Elaborado pelos autores.

Por outro lado, na Tabela 17 e na Figura 19 estão ilustrados os resultados obtidos para os testes realizados na base de dados do X (Twitter).


Dataset X (Twitter)

Modelo	Acurácia	F1	Precisão	Recall
Reddit	0,516207	0,102367	0,707965	0,055172
X	0,811034	0,821615	0,778052	0,870345
Misto	0,866207	0,868742	0,852590	0,885517

Modelo	Prec. Com Dep.	Prec. Sem Dep.	Rec. Com Dep.	Rec. Sem Dep.
Reddit	0,71	0,51	0,06	0,98
X	0,78	0,85	0,87	0,75
Misto	0,85	0,88	0,89	0,85

Tabela 17 – Métricas de desempenho para o Dataset X (Twitter): Métricas Gerais (acima) e Específicas (abaixo).

Figura 19 – Gráfico das Métricas dos Modelos no Dataset Twitter



Fonte: Elaborado pelos autores.

Neste caso, pode ser observado novamente o Modelo Misto com o melhor desempenho, superando o Modelo treinado com o dataset do X. Igualmente, é observada a exceção no alto Recall Sem Depressão (Classe 0) observado no Modelo Reddit, o que indica que, ao contrário da análise anterior, este modelo categorizou grande parte do banco de dados como não depressivos, havendo muitos Falsos Negativos.

Em seguida, na Tabela 18 e na Figura 20 são exibidos os valores encontrados para as métricas encontradas nos testes realizados na base de dados Mista (Reddit e X).

Nesse dataset, o mesmo comportamento observado pelos Modelos Reddit e Twitter se mantém, com indícios de tendências para a classe negativa (Sem Depressão) e para a classe positiva (Com Depressão), respectivamente. Mais um vez, o Modelo Misto se sobressai, apresentando bastante consistência na sua performance.


Dataset Misto

Modelo	Acurácia	F1	Precisão	Recall
Reddit	0,680000	0,601032	0,797945	0,482069
X	0,722069	0,771930	0,654511	0,940690
Misto	0,861034	0,863158	0,850167	0,876552

Modelo	Prec. Com Dep.	Prec. Sem Dep.	Rec. Com Dep.	Rec. Sem Dep.
Reddit	0,8	0,63	0,48	0,88
X	0,65	0,89	0,94	0,5
Misto	0,85	0,87	0,88	0,85

Tabela 18 – Métricas de desempenho para o Dataset Misto: Métricas Gerais (acima) e Específicas (abaixo).

Figura 20 – Gráfico das Métricas dos Modelos no Dataset Misto



Fonte: Elaborado pelos autores.

Por fim, na Tabela 19 e na Figura 21 encontram-se os resultados dos testes realizados na base de dados do Facebook.


Dataset Facebook

Modelo	Acurácia	F1	Precisão	Recall
Reddit	0,538066	0,686453	0,980060	0,528211
X	0,914609	0,955087	0,961853	0,948415
Misto	0,798354	0,884774	0,976639	0,808705

Modelo	Prec. Com Dep.	Prec. Sem Dep.	Rec. Com Dep.	Rec. Sem Dep.
Reddit	0,98	0,07	0,53	0,76
X	0,96	0,12	0,95	0,16
Misto	0,98	0,12	0,81	0,57

Tabela 19 – Métricas de desempenho para o Dataset Facebook: Métricas Gerais (acima) e Específicas (abaixo).

Figura 21 – Gráfico das Métricas dos Modelos no Dataset Facebook



Fonte: Elaborado pelos autores.

No Dataset do Facebook, o Modelo Twitter obteve os melhores resultados quantitativos, alcançando 0,91 de acurácia e 0,95 de F1. Observa-se, contudo, que todos os modelos mantiveram uma precisão elevada para a classe positiva (acima

de 0,96), evidenciando uma alta confiabilidade nas classificações positivas realizadas.

4.4 Limitações do Experimento

Apesar de o estudo apresentar resultados relevantes e contribuir para a compreensão dos impactos da mudança de domínio na detecção de depressão em redes sociais online, alguns aspectos metodológicos e limitações inerentes ao processo adotado podem ser destacados. Tais pontos representam oportunidades de aprimoramento e devem ser considerados na interpretação dos resultados obtidos.

Em primeiro lugar, a seleção das bases de dados não pôde ser realizada de forma ideal, em razão da dificuldade de obtenção de conjuntos de dados de livre acesso e adequadamente documentados, especialmente no caso da plataforma X (Twitter). Dessa forma, a ausência de documentação detalhada dificulta a compreensão dos procedimentos adotados para a coleta e classificação dos dados, limitando a análise da qualidade e da consistência dessas informações.

Ainda nesse sentido, em um cenário ideal, o experimento poderia ser conduzido com um corpus de dados obtido por meio de uma mesma metodologia de coleta e anotação, respeitando questões éticas e a privacidade dos usuários, sem a necessidade de depender de bases de dados disponibilizadas por terceiros e utilizando o mesmo tipo de categorização dos dados, evitando diferenças entre classificação binária e por severidade. Por fim, preferencialmente a classificação dos textos deveria ser realizada por profissionais da área da saúde mental, garantindo maior confiabilidade às bases de dados utilizadas e maior uniformidade aos experimentos realizados.

Também é importante ressaltar que, apesar do elevado volume de dados das bases selecionadas, cada rede social apresenta suas próprias peculiaridades e comunidades internas. Dessa forma, torna-se difícil compilar um corpus que represente adequadamente toda uma plataforma, uma vez que elas são naturalmente heterogêneas e compostas por diferentes grupos de usuários, comportamentos e padrões de comunicação. Portanto, embora seja possível identificar características gerais associadas a cada rede social, existem particularidades próprias das diferen-

tes comunidades e contextos culturais de cada país, o que torna a representação completa desses ambientes um desafio adicional.

Outro ponto importante refere-se à quantidade de domínios analisados. Embora o estudo de dois domínios distintos, juntamente com um domínio complementar para validação, tenha favorecido a compreensão do problema, a inclusão de novos cenários e fontes de dados poderia aprofundar ainda mais a investigação sobre a existência e a magnitude desse impacto. Da mesma forma, o treinamento de modelos ainda mais generalistas, utilizando dados provenientes de um número maior de redes sociais online, poderia fornecer evidências mais conclusivas acerca dos benefícios ou limitações dessa abordagem. Isso permitiria avaliar se a ampliação da diversidade de domínios contribui para um melhor desempenho e capacidade de generalização ou se, por outro lado, resulta em modelos mais genéricos e com menor sensibilidade para identificar indícios de depressão em diferentes contextos.

Também nessa vertente, seria relevante a aplicação do experimento utilizando diferentes modelos de inteligência artificial para a tarefa de classificação, a fim de verificar se o comportamento observado neste estudo se mantém em outras arquiteturas. Tal investigação permitiria avaliar se determinados modelos são menos sensíveis à mudança de domínio e mais capazes de identificar padrões gerais associados à depressão, tornando-se potencialmente mais adaptáveis a diferentes redes sociais online e contextos de aplicação.

Por fim, investigar de forma mais aprofundada os possíveis fatores responsáveis pelos impactos observados também se apresenta como uma importante oportunidade de continuidade deste estudo. A análise de aspectos como diferenças de vocabulário, padrões de comunicação e particularidades linguísticas entre as redes sociais online pode contribuir para uma compreensão mais profunda do problema, auxiliando na identificação das causas que levam à redução de desempenho dos modelos em cenários de mudança de domínio.

4.5 Considerações do Experimento

O Modelo Misto proposto, dado as condições do experimento, superou as expectativas iniciais apresentando desempenho significativo e performando de ma-

neira superior aos modelos que foram treinados única e exclusivamente no seu dataset correspondente. A diferença pode ser vista como uma melhora relevante e expressiva, considerando que os modelos específicos (Reddit e X) já apresentavam uma boa performance, apresentando variação de $\sim 4,5\%$ no F1 no Dataset Reddit e $\sim 4,7\%$ no F1 do Dataset X.

No dataset do Facebook, observa-se um resultado discrepante em relação aos experimentos anteriores, com o modelo treinado no Twitter apresentando métricas superiores de desempenho. Entretanto, ao analisar os resultados de recall para cada classe, percebe-se uma grande tendência do modelo para a classe positiva, classificando quase todos os textos como depressivos, o que como consequência resulta em uma alta precisão para tal classe. Isso, aliado ao fato de a base de dados apresentar a maioria de seus dados como depressivos, fez com que o modelo do Twitter obtivesse os melhores resultados nesta base.

Analisando além da influência da distribuição dos dados, nota-se que os modelos possuem comportamentos distintos e consistentes: o Modelo Reddit atua de forma conservadora, priorizando a precisão em suas classificações; o Modelo X (Twitter) atua de forma agressiva, priorizando a abrangência (Recall) na identificação da classe positiva; e o Modelo Misto demonstra maior capacidade de equilíbrio, combinando a alta confiabilidade do Modelo Reddit com a maior sensibilidade do Modelo Twitter, consolidando-se como a arquitetura mais equilibrada entre as testadas.

Em conclusão, ao retomar a Questão de Pesquisa (QP) norteadora "*A mudança de domínio impacta negativamente na performance do modelo?*" e as hipóteses formuladas, os resultados obtidos permitem uma resposta clara: a hipótese alternativa é corroborada, evidenciando a existência do impacto negativo especulado, enquanto a hipótese nula é refutada. Essa conclusão é sustentada pelas métricas coletadas, uma vez que houve uma queda expressiva nos resultados dos modelos quando estes foram aplicados em bases de domínios distintos daquele de sua origem.

Tal afirmação se fundamenta no fato de que, entre os experimentos realizados, a única alteração consistiu na fonte dos dados utilizados no treinamento dos

modelos, mantendo-se a mesma técnica de IA e o mesmo processo de treinamento. Além disso, foram aplicados tratamentos em ambas as bases com o objetivo de alcançar o máximo equilíbrio possível entre os cenários analisados. Dessa forma, as diferenças observadas restringem-se ao conteúdo dos dados e aos seus padrões e particularidades provenientes de cada rede social, o que sustenta a interpretação de que esse fator é, muito provavelmente, a principal causa da discrepância nos resultados.

Em complemento, o bom desempenho do modelo misto nos cenários avaliados sugere também que a generalização do modelo pode ter impacto positivo na classificação. Isso indica que um modelo treinado com dados provenientes de diferentes redes sociais online pode ser capaz de incorporar características de múltiplos domínios, tornando-se mais flexível e versátil na classificação dos textos, além de menos dependente de um único domínio para apresentar bom desempenho.

5 Conclusão

Ao longo deste trabalho, foram investigados diferentes aspectos relacionados à detecção de depressão em redes sociais, permitindo uma análise abrangente do problema proposto. Retomando os objetivos originalmente estabelecidos, pode-se afirmar que foram alcançados com sucesso. Por meio da realização das etapas previstas para o estudo exploratório e para o experimento, foi possível atender aos objetivos específicos da pesquisa e, conseqüentemente, atingir o objetivo estipulado: *mapear técnicas e métodos de Inteligência Artificial propostos na literatura acadêmica para a detecção de indícios de depressão manifestados em ambientes online*.

O estudo exploratório realizado permitiu mapear o panorama atual da aplicação de técnicas de Inteligência Artificial para a detecção de depressão em redes sociais, identificando as principais abordagens, tecnologias e tendências presentes na literatura recente. Essa etapa evidenciou não apenas o crescente interesse da comunidade científica pelo tema, mas também a diversidade de estratégias empregadas para lidar com o problema, refletindo sua complexidade e relevância. Além disso, a análise dos trabalhos permitiu compreender melhor os desafios existentes na área, as oportunidades de pesquisa ainda em aberto e os fatores que podem influenciar o desempenho das soluções propostas. Dessa forma, o estudo exploratório forneceu uma base teórica e contextual sólida, contribuindo para a geração de conhecimento sobre o tema e fornecendo os subsídios necessários para a condução da etapa experimental deste trabalho.

Este experimento, por sua vez, aprofundou e expandiu os achados obtidos na etapa anterior, permitindo uma compreensão mais aprofundada sobre os impactos da mudança de domínio em tarefas de detecção de depressão em redes sociais. Os resultados obtidos evidenciaram que esse efeito constitui um desafio relevante, demonstrando que o desempenho dos modelos é fortemente influenciado pelo contexto em que os dados são produzidos e pelas particularidades de cada plataforma. Ao mesmo tempo, observou-se que o modelo treinado com da-

dos provenientes de múltiplos domínios apresentou desempenho mais equilibrado e consistente nos diferentes cenários avaliados, superando inclusive os modelos especializados em suas respectivas bases de origem. Tal resultado sugere que a diversidade de contextos presentes nos dados de treinamento pode contribuir para uma maior capacidade de generalização dos modelos. Nesse sentido, modelos treinados com informações provenientes de diferentes redes sociais parecem apresentar uma tendência a desenvolver representações mais abrangentes dos padrões associados à depressão, tornando-se potencialmente menos dependentes das particularidades de uma única plataforma e mais adaptáveis a diferentes cenários de aplicação.

Diante dos resultados obtidos, é possível verificar que o trabalho contribuiu para ampliar a compreensão sobre a aplicação de técnicas de Inteligência Artificial na detecção de depressão em redes sociais, tanto por meio da exploração do cenário atual da literatura quanto pela investigação prática dos efeitos da mudança de domínio no desempenho dos modelos. Os achados apresentados permitiram responder às questões que motivaram a pesquisa e fornecer evidências relevantes sobre os desafios associados à generalização dessas soluções em diferentes contextos digitais. Dessa forma, o estudo agrega conhecimento a uma temática atual e de elevada relevância social, oferecendo subsídios que podem apoiar investigações futuras e aprofundar a compreensão dos fatores que influenciam a aplicação de modelos de Inteligência Artificial no contexto da saúde mental digital.

5.1 Trabalhos Futuros

No que diz respeito ao estudo exploratório, seria relevante ampliar as informações coletadas, agregando aspectos como os resultados e métricas obtidos pelos modelos abordados, bem como seus principais diferenciais e características, permitindo um aprofundamento ainda maior na análise dos trabalhos identificados. Além disso, torna-se essencial o monitoramento contínuo da literatura, uma vez que se trata de uma área em constante crescimento, que apresenta um volume cada vez maior de pesquisas e novas abordagens.

Já em relação ao experimento, trabalhos futuros relevantes incluem a ampli-

ação do escopo e o aprimoramento do processo de obtenção de dados, preferencialmente por meio de uma metodologia uniforme entre as diferentes redes sociais, com a anotação e categorização realizadas por profissionais capacitados, de modo a mitigar as limitações identificadas nesta etapa.

Outra possibilidade de investigação consiste na aplicação das técnicas não apenas para classificação binária, mas também para a estimativa do grau de severidade da depressão, o que pode aprofundar a compreensão do problema e evidenciar desafios adicionais relacionados à sutileza entre diferentes níveis do transtorno, especialmente nos casos mais leves, em que os sinais podem ser menos explícitos.

Por fim, também seria relevante expandir os experimentos para outros contextos linguísticos e culturais, incluindo dados em língua portuguesa e provenientes de usuários brasileiros, por exemplo, a fim de avaliar o impacto da variação de idioma e de cultura no desempenho dos modelos, bem como verificar se as diferenças observadas entre redes sociais se mantêm em diferentes populações.

Referências

AKIB, M.; FERDOUS, J.; MAHZABEEN, F.; KHAN, R. Enhancing mental health disorder classification: A decision tree-based approach with optimized feature engineering, data balancing, and hyperparameter tuning. In: . [S.l.: s.n.], 2025. p. 1539–1543.

American Psychiatric Association. **Manual Diagnóstico e Estatístico de Transtornos Mentais: DSM-5**. 5. ed. Porto Alegre: Artmed, 2014. Revisão técnica: Aristides Volpato Cordioli (coord.), Christian Kieling, Cristiano Tschiedel Belem da Silva, Ives Cavalcante Passos, Mário Tregnago Barcellos.

ANGSKUN, J.; TIPPRASERT, S.; ANGSKUN, T. Big data analytics on social networks for real-time depression detection. **Journal of Big Data**, v. 9, n. 1, p. 69, 2022. Disponível em: <<https://doi.org/10.1186/s40537-022-00622-2>>.

Backlinko Team. **Social Media Usage & Growth Statistics**. 2025. <<https://backlinko.com/social-media-users>>. Acessado em: 03 de novembro de 2025.

BAYDILI, .; TASCI, B.; TASCI, G. Deep learning-based detection of depression and suicidal tendencies in social media data with feature selection. **Behavioral Sciences**, v. 15, n. 3, 2025. ISSN 2076-328X. Disponível em: <<https://www.mdpi.com/2076-328X/15/3/352>>.

BEHERA, N.; KHUNTIA, S.; PANDEY, K.; SHANKAR, S. Impact of social media use on physical, mental, social, and emotional health, sleep quality, body image, and mood: Evidence from 21 countries—a systematic literature review with narrative synthesis. **International Journal of Behavioral Medicine**, nov. 2025. Epub ahead of print.

BERGMANN, D. **What is Machine Learning?** IBM Think, 2024. Accessed: 2026-04-07. Disponível em: <<https://www.ibm.com/think/topics/machine-learning>>.

BIRJALI, M.; KASRI, M.; BENI-HSSANE, A. A comprehensive survey on sentiment analysis: Approaches, challenges and trends. **Knowledge-Based Systems**, Elsevier, v. 226, p. 107134, 2021.

BOYD, R. L.; ASHOKKUMAR, A.; SERAJ, S.; PENNEBAKER, J. W. The development and psychometric properties of liwc-22. **Austin, TX: University of Texas at Austin**, v. 10, n. 1-47, p. 6, 2022.

BRITO, T. R. T. de; MAIA, D. C. M.; MILANEZ, A. F. Rede social: Seus impactos na comunicação. **Anais do Encontro de Computação do Oeste Potiguar ECOP/UFERSA (ISSN 2526-7574)**, v. 2, n. 5, 2021.

BUCUR, A.-M.; CHULVI, B.; COSMA, A.; ROSSO, P. The expression of happiness in social media of individuals reporting depression. **IEEE Transactions on Affective Computing**, IEEE, v. 16, n. 1, p. 360–375, 2024.

BUCUR, A.-M.; MOLDOVAN, A.; PARVATIKAR, K.; ZAMPIERI, M.; KHUDBUKHSH, A.; DINU, L. Datasets for depression modeling in social media: An overview. In: **Proceedings of the 10th Workshop on Computational Linguistics and Clinical Psychology (CLPsych 2025)**. Albuquerque, New Mexico: Association for Computational Linguistics, 2025. p. 116–126. Disponível em: <<https://aclanthology.org/2025.clpsych-1.10/>>.

CAMPOS, R. S. Desmistificando a inteligencia artificial:: uma breve introdução conceitual ao aprendizado de maquina. **Aoristo-International Journal of Phenomenology, Hermeneutics and Metaphysics**, v. 3, n. 1, p. 106–123, 2020.

Columbia University Libraries. **Text Mining: Social Media**. n.d. <<https://guides.library.columbia.edu/text-mining/social-media>>. Acesso em: 06 abr. 2026.

COZMAN, F. G.; PLONSKI, G. A.; NERI, H. Inteligencia artificial: avanços e tendências. **Center for Artificial Intelligence. Instituto de Estudos Avançados (IEA) da Universidade de S ao Paulo (USP)**, 2021.

CRUZ-RAMIREZ, Y. M. D. L.; OLAZA-MAGUIÑA, A. F. Digital divide and social media related to smart e-learning in obstetrics during the health emergency by covid-19 in peru. In: USKOV, V. L.; HOWLETT, R. J.; JAIN, L. C. (Ed.). **Smart Education and e-Learning 2021**. Singapore: Springer Singapore, 2021. p. 111–119. ISBN 978-981-16-2834-4.

DEVLIN, J.; CHANG, M.-W.; LEE, K.; TOUTANOVA, K. Bert: Pre-training of deep bi-directional transformers for language understanding. In: **Proceedings of the 2019 conference of the North American chapter of the association for computational linguistics: human language technologies, volume 1 (long and short papers)**. [S.l.: s.n.], 2019. p. 4171–4186.

DORES, A. F. d. Reconhecimento de padrões com inteligência artificial. 2018.

EASLEY, D. *et al.* **Networks, crowds, and markets: Reasoning about a highly connected world**. [S.l.: s.n.], 2010. v. 1.

EISENSTEIN, E. Crianças, adolescentes e a era digital: benefícios e riscos. **Revista Acadêmica Licencia&acturas**, v. 11, n. 1, p. 7–14, 2023.

FACE, H. **Hugging Face Transformers: Trainer API**. 2026. <https://huggingface.co/docs/transformers/main_classes/trainer>. Acessado em: 05 de maio de 2026.

FACEBOOKAI. **RoBERTa base model**. 2026. <<https://huggingface.co/FacebookAI/roberta-base>>. Acessado em: 05 de maio de 2026.

FILHO, S. L.; SILVA, M.; OLIVEIRA, J. Identificação de sintomas de depressão por dados de mídias sociais: Aplicando design science research para desenvolver um modelo de classificação. In: **Anais Estendidos do XX Simpósio Brasileiro de Sistemas de Informação**. Porto Alegre, RS, Brasil: SBC, 2024. p. 1–15. ISSN 0000-0000. Disponível em: <https://sol.sbc.org.br/index.php/sbsi_estendido/article/view/28591>.

GIL, A. C. *et al.* **Como elaborar projetos de pesquisa**. [S.l.]: Atlas São Paulo, 2002. v. 4.

Global Web Index. **Social Media Trends in 2024**. 2024. <<https://www.gwi.com/reports/social-media-trends-2024>>. Dashboard com acesso apenas para visualização. Dados baseados na pesquisa GWI Core em mais de 50 mercados. Acessado em: 03 de novembro de 2025.

GOH, Y. S.; SEE, Q. R.; VONGSIRIMAS, N.; KLANIN-YOBAS, P. Artificial intelligence in diagnosing depression through behavioural cues: A diagnostic accuracy systematic review and meta-analysis. **Journal of Clinical Nursing**, Wiley Online Library, 2025.

GOMES, L. C. N. Inteligência artificial e ética em saúde. **Brazilian Journal of Development**, v. 11, n. 1, p. e76710–e76710, 2025.

HUANG, L.; YU, W.; MA, W.; ZHONG, W.; FENG, Z.; WANG, H.; CHEN, Q.; PENG, W.; FENG, X.; QIN, B. *et al.* A survey on hallucination in large language models: Principles, taxonomy, challenges, and open questions. **ACM Transactions on Information Systems**, ACM New York, NY, v. 43, n. 2, p. 1–55, 2025.

Hugging Face. **Transformers Callbacks Documentation**. [S.l.], 2026. Acessado em: 30 de maio de 2026. Disponível em: <https://huggingface.co/docs/transformers/main_classes/callback>.

INFAMOUSCODER. **Mental Health Social Media**. 2022. <<https://www.kaggle.com/datasets/infamouscoder/mental-health-social-media>>. Acessado em: 05 de maio de 2026.

JÚLIO, J. G. Inteligência artificial e depressão: revisão sistemática. **Revista da UI_IPSantarém**, v. 12, n. 1, p. e33936–e33936, 2024.

JURAFSKY, D. **Speech & Language Processing**. Pearson Education, 2000. (Pearson Education Series in Artificial Intelligence). ISBN 9788131716724. Disponível em: <<https://books.google.com.br/books?id=LCnx6xaDZsIC>>.

JURAFSKY, D.; MARTIN, J. H. **Speech and Language Processing: An Introduction to Natural Language Processing, Computational Linguistics, and Speech Recognition with Language Models**. 3rd. ed. [s.n.], 2026. Online manuscript released January 6, 2026. Disponível em: <<https://web.stanford.edu/~jurafsky/slp3/>>.

KARAMI, A.; LUNDY, M.; WEBB, F.; DWIVEDI, Y. K. Twitter and research: A systematic literature review through text mining. **IEEE Access**, IEEE, v. 8, p. 67698–67717, 2020.

KAYALVIZHI, S.; THENMOZHI, D. Data set creation and empirical analysis for detecting signs of depression from social media postings. In: KALINATHAN, L.; R., P.; KANMANI, M.; S., M. (Ed.). **Computational Intelligence in Data Science**. Cham: Springer International Publishing, 2022. p. 136–151. ISBN 978-3-031-16364-7.

KHALID, O.; SRINIVASAN, P. Style matters! investigating linguistic style in online communities. In: **Proceedings of the international AAAI conference on web and social media**. [S.l.: s.n.], 2020. v. 14, p. 360–369.

KMETTY, Z.; BOZSONYI, K. Identifying depression-related behavior on facebook an experimental study. **Social Sciences**, MDPI, v. 11, n. 3, p. 135, 2022.

KOUKARAS, P.; TJORTJIS, C.; ROUSIDIS, D. Social media types: introducing a data driven taxonomy. **Computing**, v. 102, 01 2020.

LAMHARMECH, C.; KHADIJA, A.; ABDELOUAHID, R. A.; ABDELAZIZ, M. Leveraging ibm tools and social media insights for postpartum depression prediction. In: . [S.l.: s.n.], 2025. p. 1–8.

LECUN, Y.; BENGIO, Y.; HINTON, G. Deep learning. **Nature**, v. 521, n. 7553, p. 436–444, 2015. Disponível em: <<https://doi.org/10.1038/nature14539>>.

LI, N.; HUANG, Q.; GE, X.; HE, M.; CUI, S.; HUANG, P.; LI, S.; FUNG, S.-F. A review of the research progress of social network structure. **Complexity**, Wiley Online Library, v. 2021, n. 1, p. 6692210, 2021.

LIAW, A. S.; CHUA, H. N. Depression detection on social media with user network and engagement features using machine learning methods. In: IEEE. **2022 IEEE International Conference on Artificial Intelligence in Engineering and Technology (IICAIET)**. [S.l.], 2022. p. 1–6.

LIU, Y.; OTT, M.; GOYAL, N.; DU, J.; JOSHI, M.; CHEN, D.; LEVY, O.; LEWIS, M.; ZETTLEMOYER, L.; STOYANOV, V. Roberta: A robustly optimized bert pretraining approach. **arXiv preprint arXiv:1907.11692**, 2019.

LYBECK, R.; KOIRANEN, I.; KOIVULA, A. From digital divide to digital capital: the role of education and digital skills in social media participation. **Universal Access in the Information Society**, v. 23, n. 4, p. 1657–1669, 2024. ISSN 1615-5297. Disponível em: <<https://doi.org/10.1007/s10209-022-00961-0>>.

MATOS, K. A.; GODINHO, M. O. D. A influência do uso excessivo das redes sociais na saúde mental de adolescentes: uma revisão integrativa. **Revista Foco**, v. 17, n. 4, p. e4716–e4716, 2024.

MEHRABI, N.; MORSTATTER, F.; SAXENA, N.; LERMAN, K.; GALSTYAN, A. A survey on bias and fairness in machine learning. **ACM Comput. Surv.**, Association for Computing Machinery, New York, NY, USA, v. 54, n. 6, jul. 2021. ISSN 0360-0300. Disponível em: <<https://doi.org/10.1145/3457607>>.

MIHOV, I.; CHEN, H.; QIN, X.; KU, W.-S.; YAN, D.; LIU, Y. Mentalnet: Heterogeneous graph representation for early depression detection. In: **2022 IEEE International Conference on Data Mining (ICDM)**. [S.l.: s.n.], 2022. p. 1113–1118. ISSN 2374-8486.

MILLER, C.; PORTLOCK, T.; NYAGA, D. M.; OSULLIVAN, J. M. A review of model evaluation metrics for machine learning in genetics and genomics. **Frontiers in bioinformatics**, Frontiers Media SA, v. 4, p. 1457619, 2024.

MUTHU, D.; ELAKKIA, G.; TAMILSELVI, B. DeepMindWatch: A Multi Modal AI Framework for Early Detection of Depression and Anxiety from Digital Bio Markers. In: **2025 4th International Conference on Innovative Mechanisms for Industry Applications (ICIMIA)**. [S.l.: s.n.], 2025. p. 1974–1978.

NASEEM, U.; DUNN, A. G.; KIM, J.; KHUSHI, M. Early identification of depression severity levels on reddit using ordinal classification. In: **Proceedings of the ACM Web Conference 2022**. [S.l.: s.n.], 2022. p. 2563–2572.

NORDMO, M.; KLEPPESTØ, T. H.; REME, B.-A.; SUNDE, H. F.; SOEST, T. von; TORVIK, F. A. The diminishing association between adolescent mental disorders and educational performance from 2006 to 2019. **JCPP Advances**, Wiley, v. 4, n. 3, p. e12239, 2024. Acesso em: nov. 2025. Disponível em: <<https://acamh.onlinelibrary.wiley.com/doi/10.1002/jcv2.12239>>.

OLIVEIRA, T. *et al.* O papel das plataformas de redes sociais na subversão do conceito de comunidade virtual: elementos para a compreensão da construção da subjetividade contemporânea. Pontifícia Universidade Católica de São Paulo, 2023.

OMS. **Pandemia de COVID-19 provoca aumento de 25% na prevalência de ansiedade e depressão em todo o mundo**. 2022. Comunicado de imprensa. Disponível em: <https://www.who.int/news/item/02-03-2022-covid-19-pandemic-triggers-25-increase-in-prevalence-of-anxiety-and-depression-worldwide>.

OMS. **Transtorno depressivo (depressão) Ficha informativa**. 2025. Publicado em 29 de agosto de 2025. Organização Mundial da Saúde, Genebra, Suíça.

OMS. **Transtornos mentais Ficha informativa**. 2025. Publicado em 30 de setembro de 2025. Organização Mundial da Saúde, Genebra, Suíça.

Pennebaker Conglomerates, Inc. **LIWC-22 Help**. [S.l.], 2022. Accessed: 2026-06-24. Disponível em: <https://www.liwc.app/help/liwc>.

PRADNYANA, G. A.; ANGGRAENI, W.; YUNIARNO, E. M.; PURNOMO, M. H. Revealing depression through social media via adaptive gated cross-modal fusion augmented with insights from personality traits. **IEEE Access**, Institute of Electrical and Electronics Engineers Inc., v. 13, p. 133465–133482, 2025. ISSN 2169-3536. Publisher Copyright: © IEEE. 2013 IEEE.

Presidência da República do Brasil. **Lei nº 12.965, de 23 de abril de 2014 (Marco Civil da Internet)**. 2014. Disponível em: http://www.planalto.gov.br/ccivil_03/_ato2011-2014/2014/lei/l12965.htm.

RAINIO, O.; TEUHO, J.; KLÉN, R. Evaluation metrics and statistical tests for machine learning. **Scientific reports**, Nature Publishing Group UK London, v. 14, n. 1, p. 6086, 2024.

RIBEIRO, R. M.; MENEZES, J. D. d. S.; POMPEO, D. A.; DINIZ, M. A. A.; LIMA, G. S.; RIBEIRO, P. C. P. S. V.; ANDRÉ, J. C.; RIBEIRO, R. d. C. H. M.; RODRIGUES, R. A. P.; KUSUMOTA, L. Beyond isolation: Social media as a bridge to well-being in old age. **International Journal of Environmental Research and Public Health**, MDPI, v. 22, n. 6, p. 882, maio 2025. ISSN 1660-4601. Published online: 2025-05-31. Disponível em: <https://doi.org/10.3390/ijerph22060882>.

RICHARDSON, W. S.; WILSON, M. C.; NISHIKAWA, J.; HAYWARD, R. S. The well-built clinical question: A key to evidence-based decisions. **ACP Journal Club**, v. 123, n. 3, p. A12–A13, nov. 1995.

RODRIGUES, L.; FERNANDES, D.; LAGO, M. P. do; FERNANDES, M.; SOARES, F.; SILVA, K. Visão sobre técnicas computacionais na detecção de depressão em texto. **Journal of Health Informatics**, v. 16, n. Especial, 2024.

RONGALI, S. K. Natural language processing (nlp) in artificial intelligence. **World Journal of Advanced Research and Reviews**, WJARR, v. 17, n. 2, p. 234240, 2025.

ROY, S.; BISWAS, A. K.; SHARMA, M. Stress, anxiety, and depression as psychological distress among college and undergraduate students: A scoping review of reviews guided by the socio-ecological model. **Healthcare**, MDPI, v. 13, n. 16, 2025. Publicado em 2025. Acesso em: novembro de 2025.

SAIWA. **How to Train an AI Model: A Comprehensive Guide**. 2024. Acessado em: 5 nov. 2025. Disponível em: <<https://medium.com/@saiwadotai/how-to-train-an-ai-model-a-comprehensive-guide-d5aefaa2763d>>.

SANTOS, T. C. A. dos; RODRIGUES, K. L. A. Impactos das redes sociais em relação à autoestima e autoimagem. **Revista Ibero-Americana de Humanidades, Ciências e Educação**, v. 9, n. 3, p. 851–862, 2023.

SEABROOK, E. M.; KERN, M. L.; FULCHER, B. D.; RICKARD, N. S. Predicting depression from language-based emotion dynamics: longitudinal analysis of facebook and twitter status updates. **Journal of medical Internet research**, JMIR Publications Toronto, Canada, v. 20, n. 5, p. e168, 2018.

SHAHABIKARGAR, M.; BEHESHTI, A.; KHATAMI, A.; NGUYEN, R.; ZHANG, X.; ALINEJAD-ROKNY, H. Domain knowledge enhanced text mining for identifying mental disorder patterns. In: IEEE. **2022 IEEE 9th International Conference on Data Science and Advanced Analytics (DSAA)**. [S.l.], 2022. p. 1–10.

SILVA, A. C. R.; MOURO, M. F.; OLIVEIRA, J. R.; OLIVEIRA, S. H. D.; FARIA, P. C. C.; CASTILHO, L. O.; QUEIROZ, L. F. E. de; DINIZ, N. A. Aplicação da inteligência artificial no âmbito das doenças psiquiátricas: Uma revisão bibliográfica. 2025.

SILVEIRA, R. Uso de big data para análise de dados em redes sociais. AMF, 2016.

SOUZA, R. de F.; TOZATTO, A. Redes sociais e os impactos na formação da identidade dos adolescentes. **Revista Sociedade Científica**, v. 7, n. 1, p. 5279–5294, 2024.

TANG, J.; GUO, Q.; ZHAO, Y.; SHANG, Y. Decoding linguistic nuances in mental health text classification using expressive narrative stories. In: IEEE. **2024 IEEE 6th International Conference on Cognitive Machine Intelligence (CogMI)**. [S.l.], 2024. p. 207–216.

TAVARES, C. dos S.; GOMES, F. A. de O. Redes sociais. **Adelia Miglievich Ribeiro–Universidade Federal do Espírito Santo Alexandre Jeronimo Correia**

Lima—Universidade Federal do Ceará Antonio Alberto Brunetta—Universidade Federal de Santa Catarina Camila Ferreira da Silva—Universidade Federal do Amazonas Daniel Gustavo Mocelin—Universidade Federal do Rio Grande do Sul, p. 97–113, 2022.

TOOSI, A.; BOTTINO, A. G.; SABOURY, B.; SIEGEL, E.; RAHMIM, A. A brief history of ai: how to prevent another winter (a critical review). **PET clinics**, Elsevier, v. 16, n. 4, p. 449–469, 2021.

VASWANI, A.; SHAZEER, N.; PARMAR, N.; USZKOREIT, J.; JONES, L.; GOMEZ, A. N.; KAISER, L.; POLOSUKHIN, I. **Attention Is All You Need**. 2023. Disponível em: <<https://arxiv.org/abs/1706.03762>>.

WOLFERS, L. N.; NEUMANN, D.; KLEIN, S. H.; GAISER, F.; ANDERL, C.; UTZ, S. What do you mean by social media? introducing the reporting items for social media research (risomer). **Annals of the International Communication Association**, Oxford University Press, v. 49, n. 3, p. 192–204, 2025.

YIP, Y. Y.; MAK MOR-BAKRY, M.; CHONG, W. W. Elements influencing user engagement in social media posts on lifestyle risk factors: Systematic review. **Journal of Medical Internet Research**, JMIR Publications, v. 26, p. e59742, 2024. Published: November 22, 2024. Disponível em: <<https://doi.org/10.2196/59742>>.